深入理解大数据-大数据处理与编程实践

Ch.6. HBase与Hive程序设计

南京大学计算机科学与技术系

主讲人：黄宜华，顾荣

鸣谢：本课程得到Google（北京）与Intel公司
中国大学合作部精品课程计划资助

Ch.6. HBase与Hive程序设计

1. HBase基本工作原理
2. HBase基本操作与编程方法示例
3. Hive基本工作原理
4. Hive基本操作示例

1. HBase基本工作原理

关系数据库的理论局限性

- RDBMS选择ACID (CAP定理中的C，然后是A）
  - 网络分片(Network Partitions)在分布式系统中不可避免
  - 系统扩展时性能和可靠性下降
- Scale up, not out
  - 并行数据库 的扩展性
    - 经验定律：当集群节点数每增加4~16台, 每个节点的效率下降一半
  - 难以扩展超过~100节点
    - TPC-C/TPC-H世界纪录: 27 servers~80 servers
- “One size does not fit all”
  - 在所有数据库的主要应用领域，新的架构轻易地有10x倍性能提升 (数据仓库, 流处理,科学计算, 非结构化数据处理，OLTP在线事务处理)*

** ACM SIGACT News, Volume 33 Issue 2 (2002): “Brewer's conjecture and the feasibility of consistent, available, partition-tolerant web services”*
** ICDE 2005: “One Size Fits All”: An Idea Whose Time Has Come and Gone*
** VLDB 2007: The End of an Architectural Era (It’s Time for a Complete Rewrite)*

1. HBase基本工作原理

RDBMS的实现局限性

- RDBMS实现和操作上的局限性 – 不适合新的应用
  - 大表 - 在一张表中存储500GB的数据?
  - 灵活动态可变的表结构 - 为大表修改表结构(Alter Table)?
  - 无停机时间的在线大表分区和动态扩容 - …

关系数据库 **vs. Hadoop/Hive**

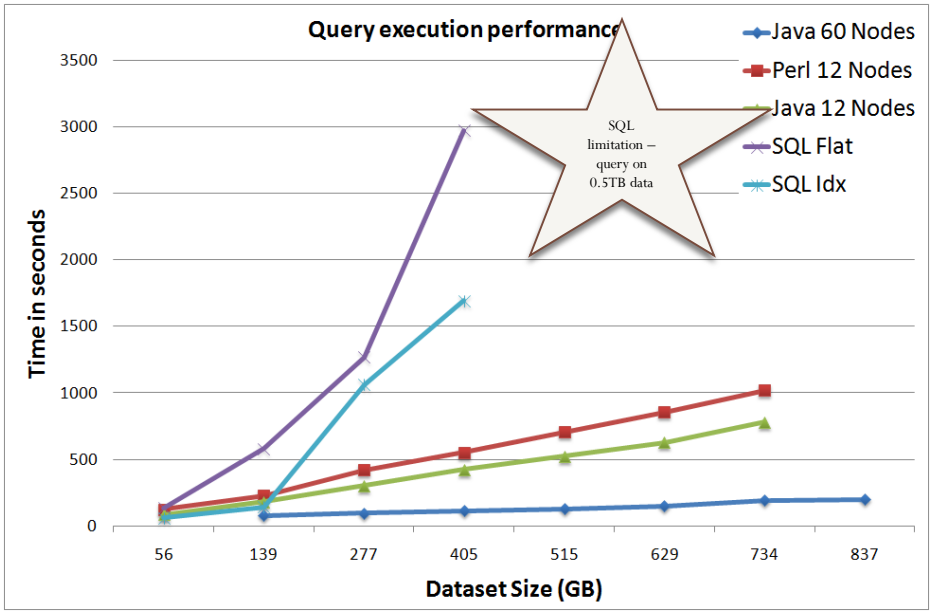

Intel silicon design environment usage analysis, 40M records/day

1. HBase基本工作原理

HBase的设计目标和功能特点

- 针对HDFS缺少结构化半结构化数据存储访问能力的缺陷，提供一个分布式数据管理系统，解决大规模的结构化和半结构化数据存储访问问题
- Google BigTable的一个开源实现
- 提供基于列存储模式的大数据表管理能力
- 可存储管理数十亿以上的数据记录，每个记录可包含百万以上的数据列
- HBase试图提供随机和实时的数据读写访问能力
- 具有高可扩展性、高可用性、容错处理能力、负载平衡能力、以及实时数据查询能力

HBase在Hadoop中的生态环境

- 构建于分布式文件系统HDFS之上
- 为上层应用提供结构化半结构化海量数据存储访问能力

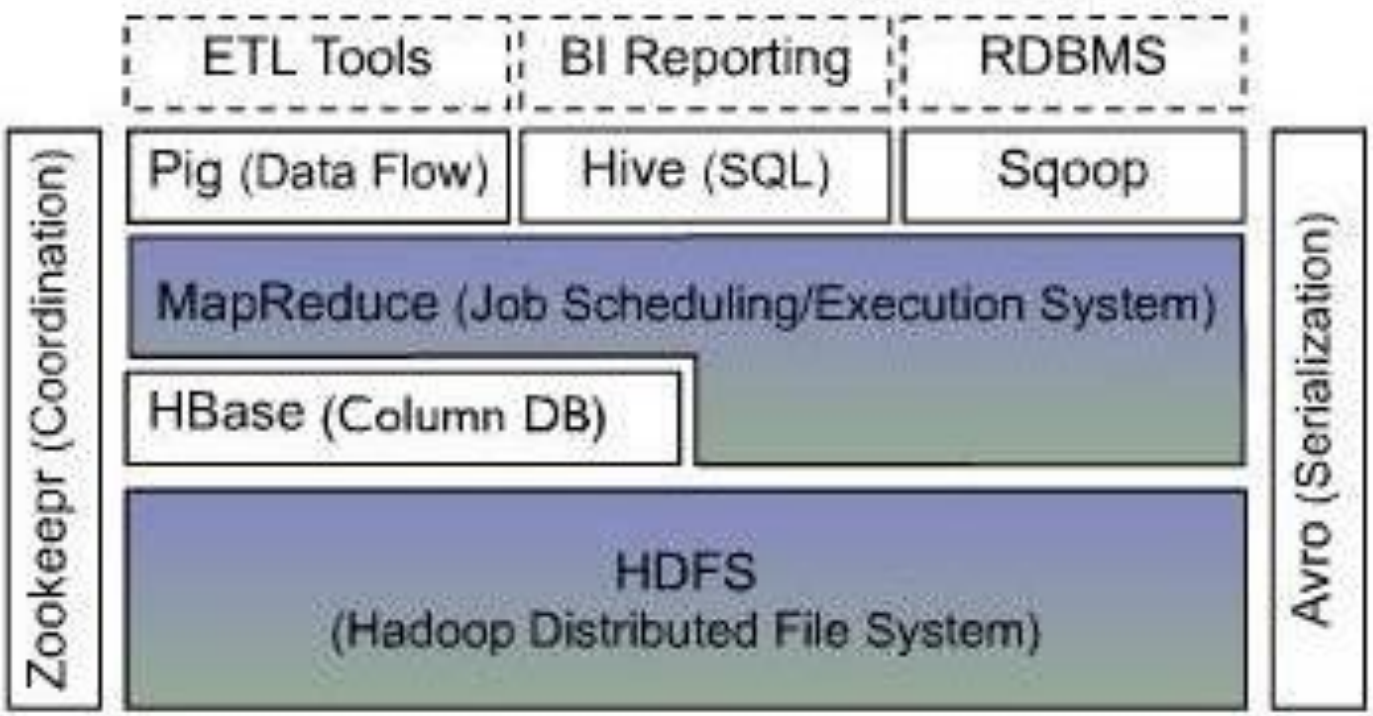

HBase在Hadoop中的生态环境

- 可与MapReduce协同工作，为MapReduce提供数据输入输出，以完成数据的并行化处理

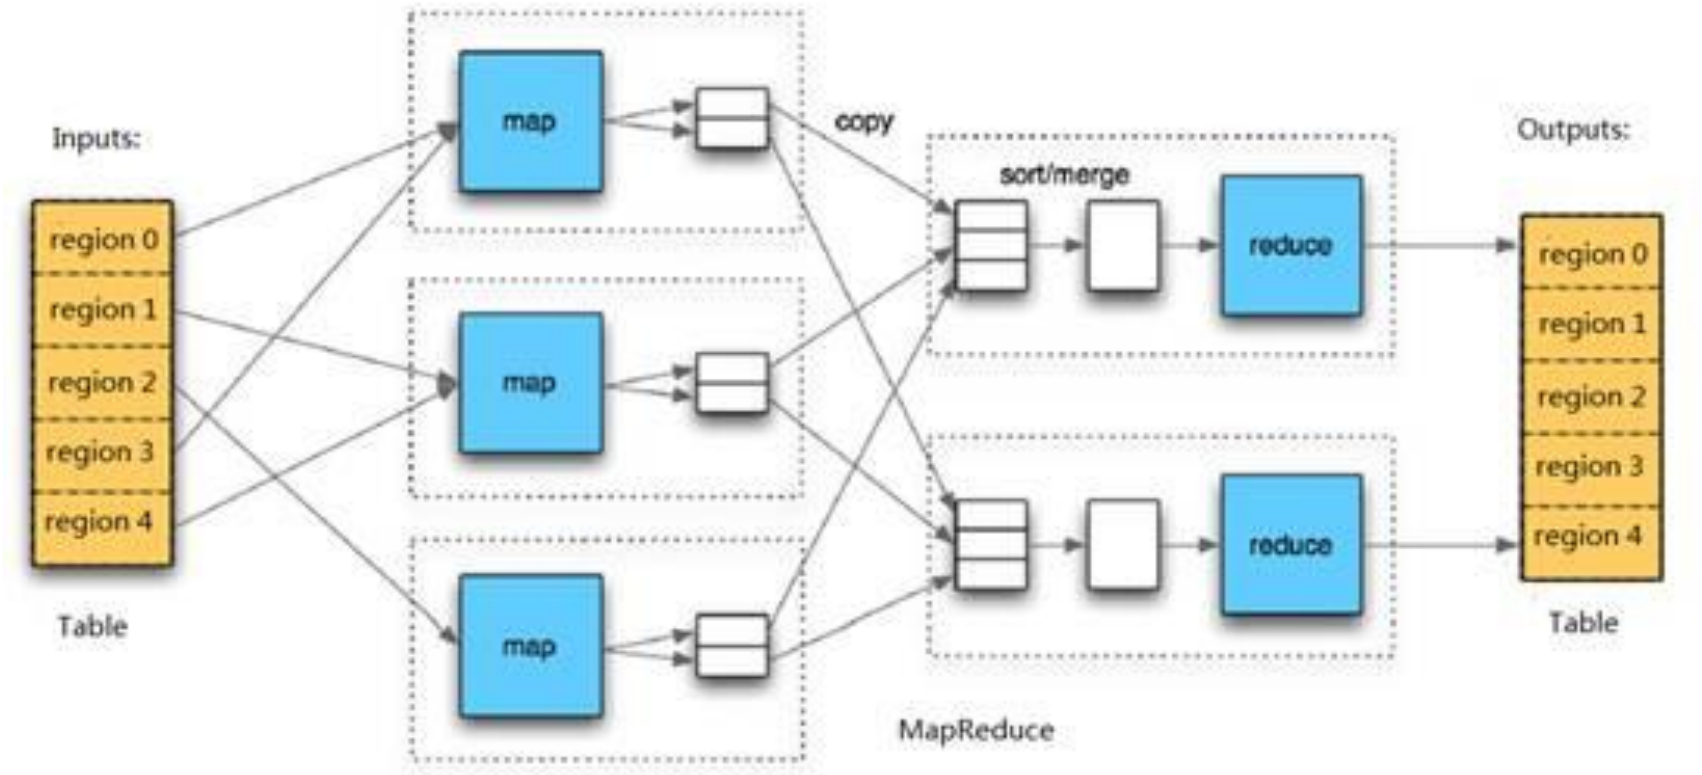

HBase数据模型

逻辑数据模型

- 数据存储逻辑模型与BigTable类似,但实现上有一些不同之处。
- 是一个分布式多维表，表中的数据通过：
  - 一个行关键字(row key)
  - 一个列关键字(column key)
  - 一个时间戳(time stamp)

进行索引和查询定位的。

行关键字	时间戳	列"contents:"	列"anchor:"		列"mime:"
"com.cnn.www"	t9		"anchor:cnnsi.com"	"CNN"	
	t8		"anchor:my.look.ca"	"CNN.com"	
	t6	"<html>..."			"text/html"
	t5	"<html>..."			
	t3	"<html>..."			

HBase数据模型

HBase物理存储格式

行关键字	时间戳	列"contents:"	
"com.cnn.www"	t6	"<html>..."	
	t5	"<html>..."	
	t3	"<html>..."	
行关键字	时间戳	列 "anchor:"	
"com.cnn.www"	t9	"anchor:cnnsi.com"	"CNN"
	t8	"anchor:my.look.ca"	"CNN.com"
行关键字	时间戳	列 "mime:"	
"com.cnn.www"	t6	"text/html"	

- 按照列存储的稀疏行/列矩阵。物理存储格式上按逻辑模型中的行进行分割，并按照列族存储。
- 值为空的列不予存储，节省存储空间。

HBase数据模型

HBase物理存储格式

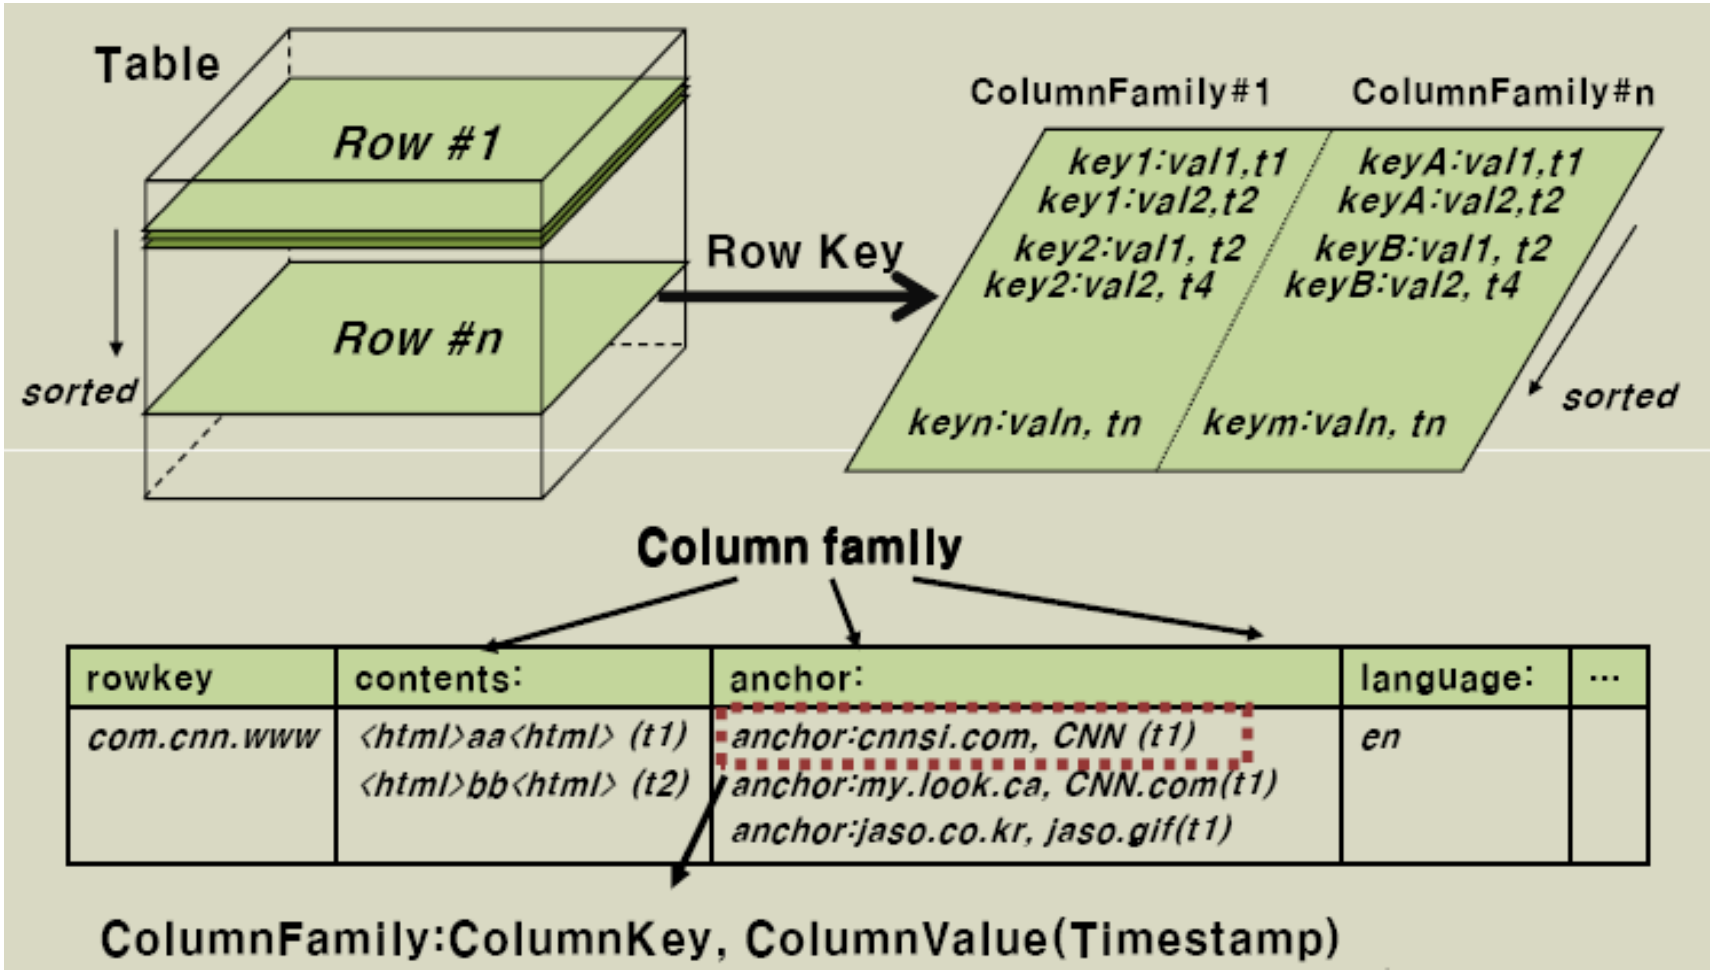

HBase的基本构架

- 由一个MasterServer和由一组子表数据区服务器RegionServer构成，分别存储逻辑大表中的部分数据
- 大表中的底层数据存于HDFS中

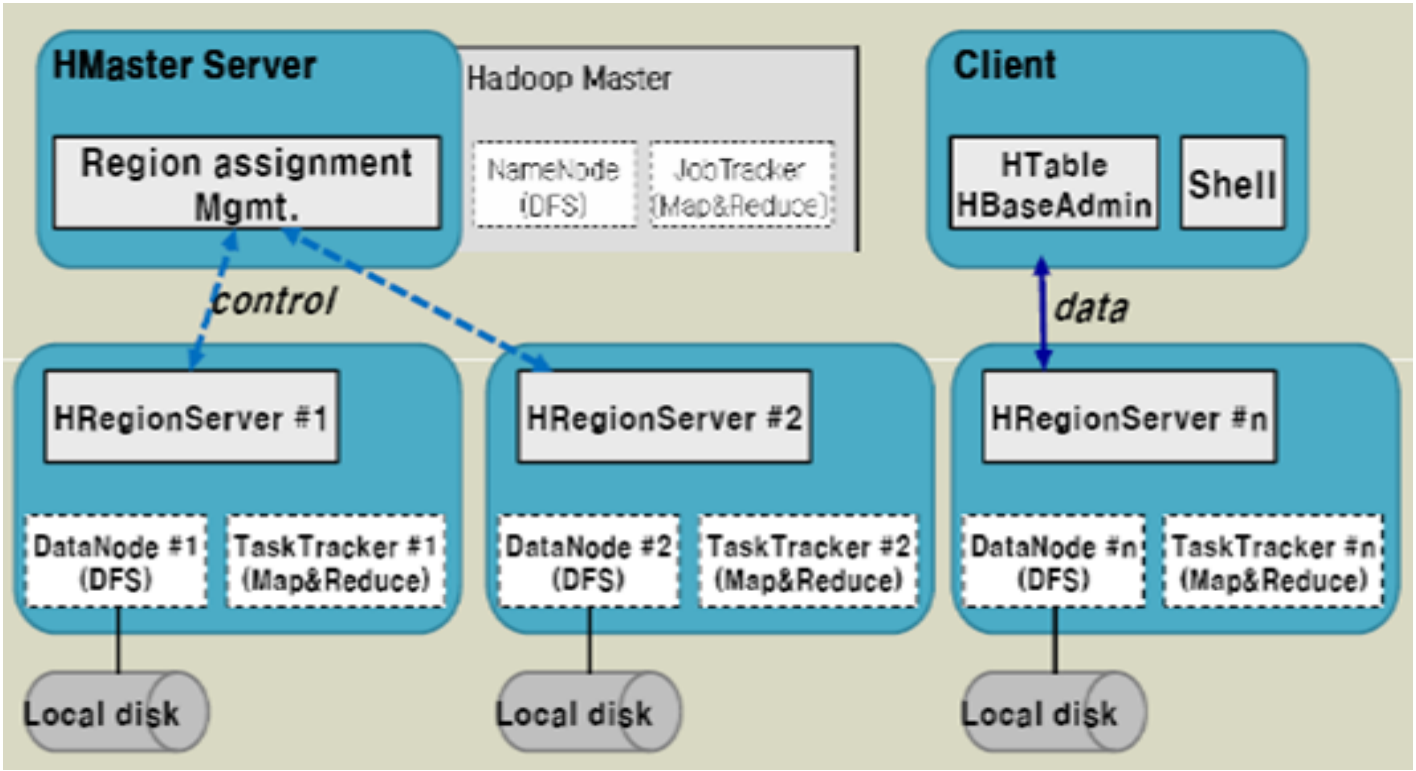

HBase数据存储管理方法

HBase子表数据存储与子表服务器

- 与BigTable类似，大表被分为很多个子表（Region），每个子表存储在一个子表服务器RegionServer上

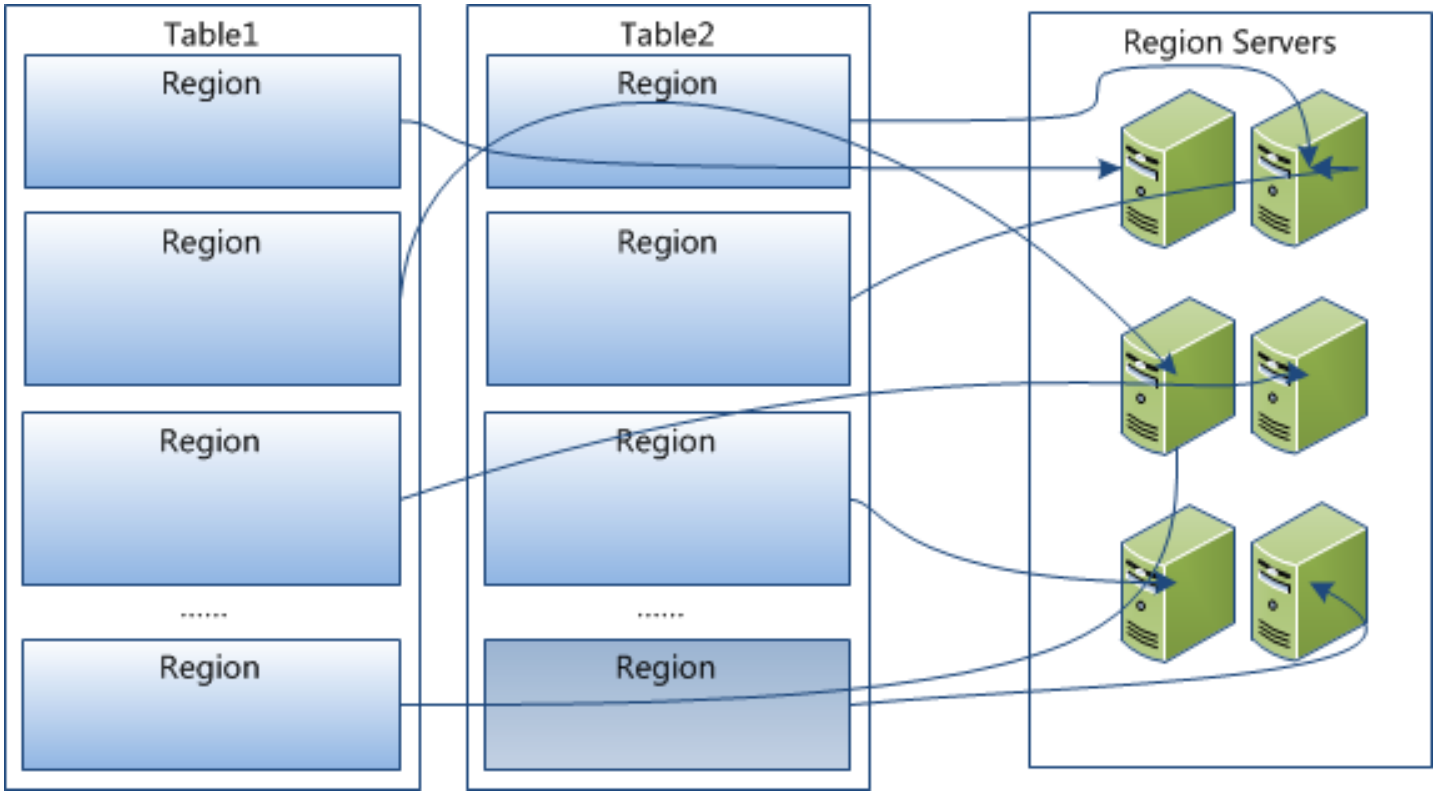

HBase数据存储管理方法

HBase子表数据存储与子表服务器

- 每个子表中的数据区Region由很多个数据存储块Store构成
- 而每个Store数据块又由存放在内存中的memStore和存放在文件中的StoreFile构成

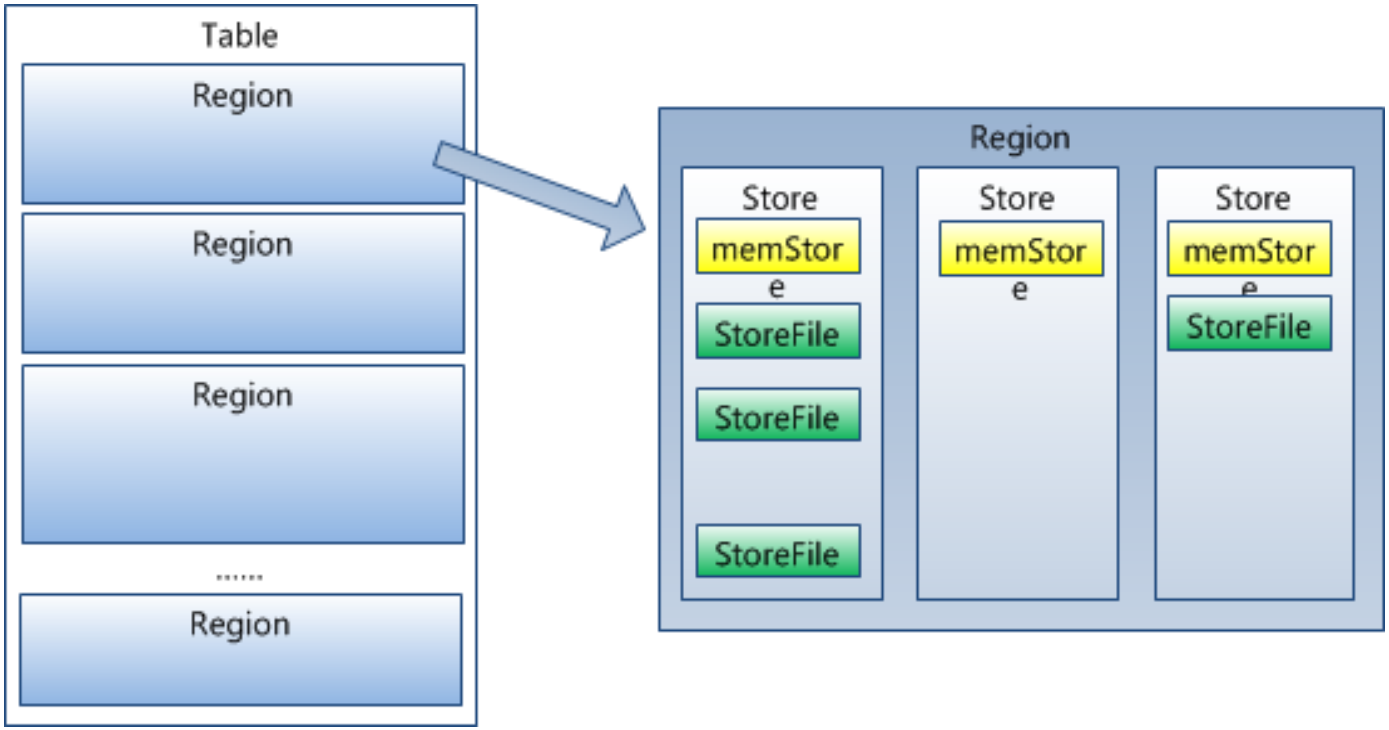

HBase数据存储管理方法

HBase子表数据存储与子表服务器

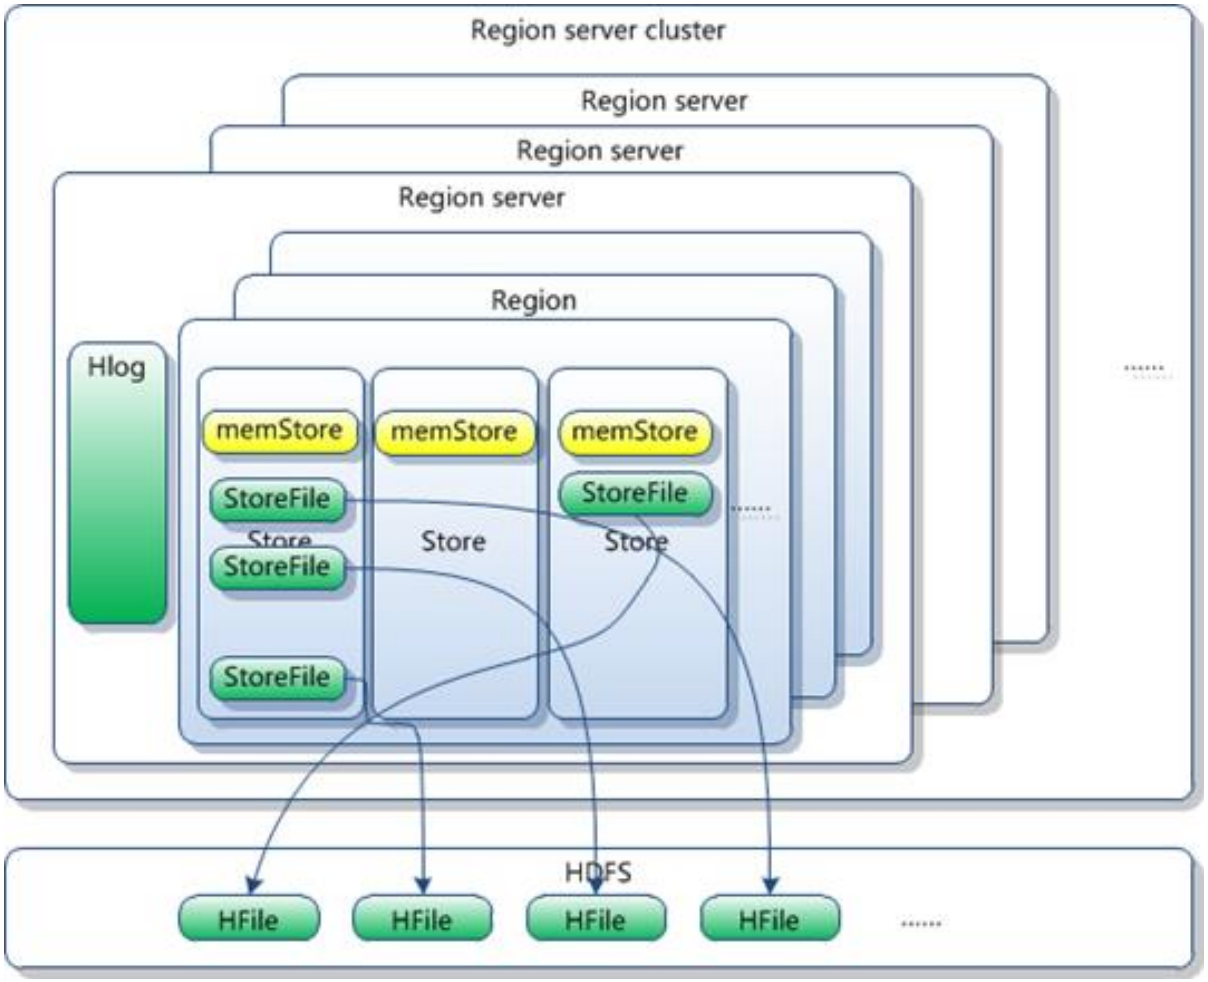

HBase数据存储管理方法

HBase数据的访问

- 当客户端需要进行数据更新时，先查到子表服务器,然后向子表提交数据更新请求。提交的数据并不直接存储到磁盘上的数据文件中，而是添加到一个基于内存的子表数据对象memStore中，当memStore中的数据达到一定大小时，系统将自动将数据写入到文件数据块StoreFile中。
- 每个文件数据块StoreFile最后都写入到底层基于HDFS的文件中

HBase数据存储管理方法

HBase数据的访问

- 需要查询数据时，子表先查memStore。如果没有，则再查磁盘上的StoreFile。每个StoreFile都有类似B树的结构，允许进行快速的数据查询。StoreFile将定时压缩，多个压缩为一个
- 两个小的子表可以进行合并
- 子表大到超过某个指定值时，子表服务器就需要调用HRegion.closeAndSplit(),把它分割为两个新的子表。

HBase数据存储管理方法

HBase子表服务器与主服务器

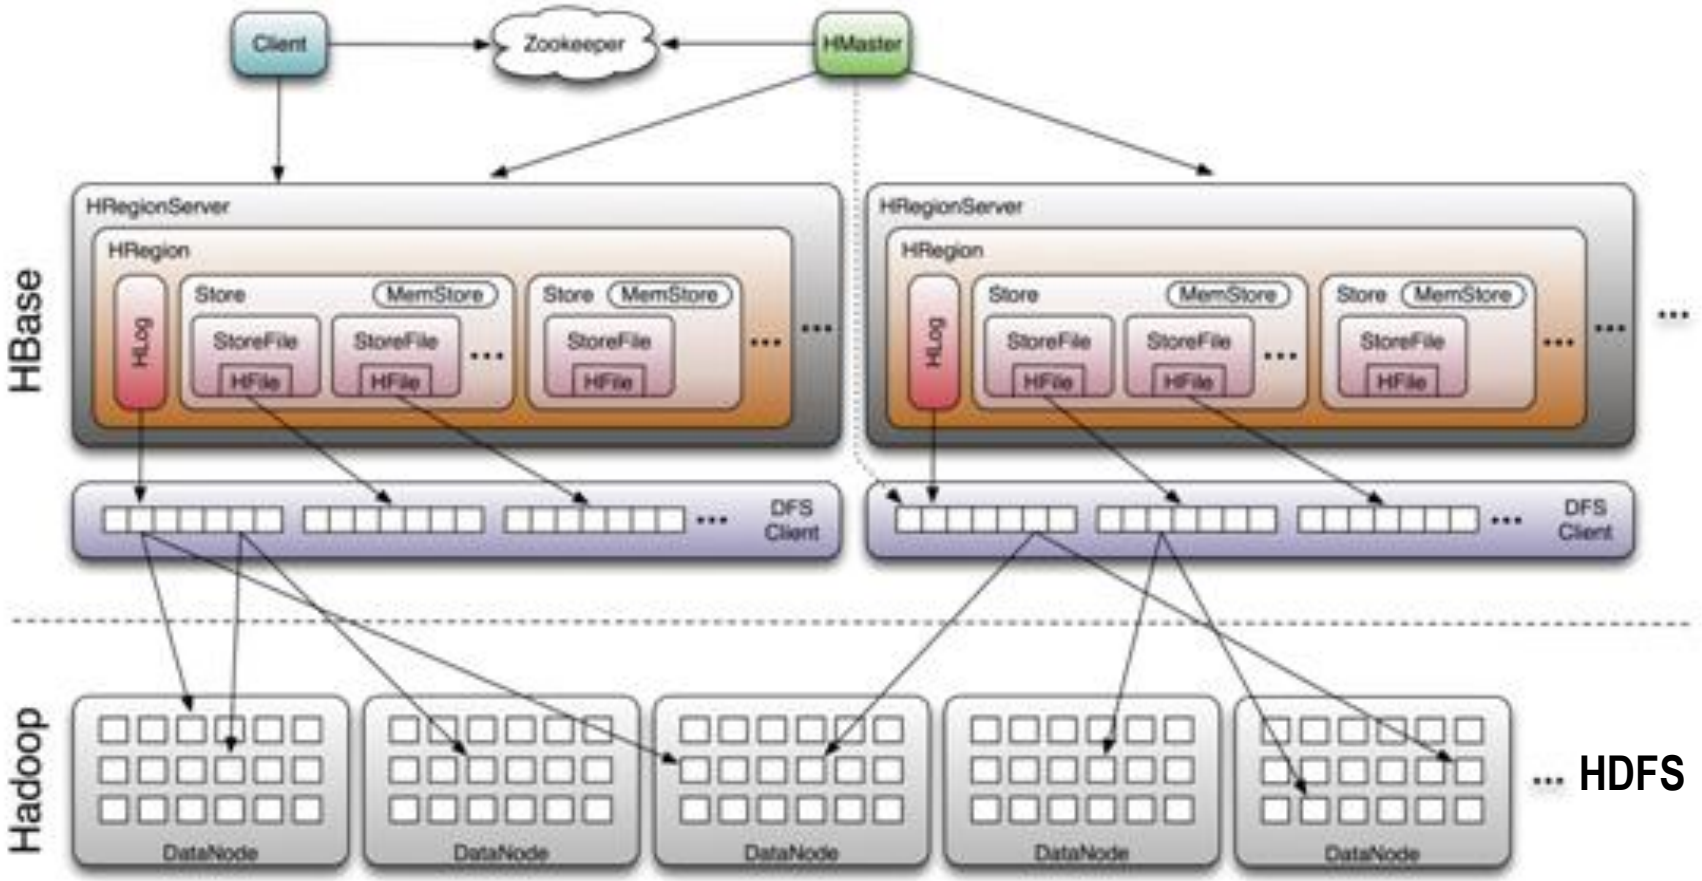

HBase数据存储管理方法

HBase主服务器HServer

- 与BigTable类似，HBase使用主服务器HServer来管理所有子表服务器。主服务器维护所有子表服务器在任何时刻的状态
- 当一个新的子表服务器注册时，主服务器让新的子表服务器装载子表
- 若主服务器与子表服务器连接超时，那么子表服务器将自动停止，并重新启动；而主服务器则假定该子表服务器已死机，将其上的数据转移至其它子表服务器，将其上的子表标注为空闲，并在重新启动后另行分配使用。

HBase数据存储管理方法

HBase数据记录的查询定位

- 描述所有子表和子表中数据块的元数据都存放在专门的元数据表中,并存储在特殊的子表中。子表元数据会不断增长，因此会使用多个子表来保存
- 所有元数据子表的元数据都保存在根子表中。主服务器会扫描根子表，从而得到所有的元数据子表位置，再进一步扫描这些元数据子表即可获得所寻找子表的位置。

HBase数据记录的查询定位

- HBase使用三层类似B+树的结构来保存region位置

  第一层是保存zookeeper里面的文件，它持有root region的位置。

  第二层root region是.META.表的第一个region，其中保存了.META.表其它region的位置。通过root region，我们就可以访问.META.表的数据。

  .META.是第三层，它是一个特殊的表，保存了HBase中所有数据表的region 位置信息。

HBase数据存储管理方法

HBase数据记录的查询定位

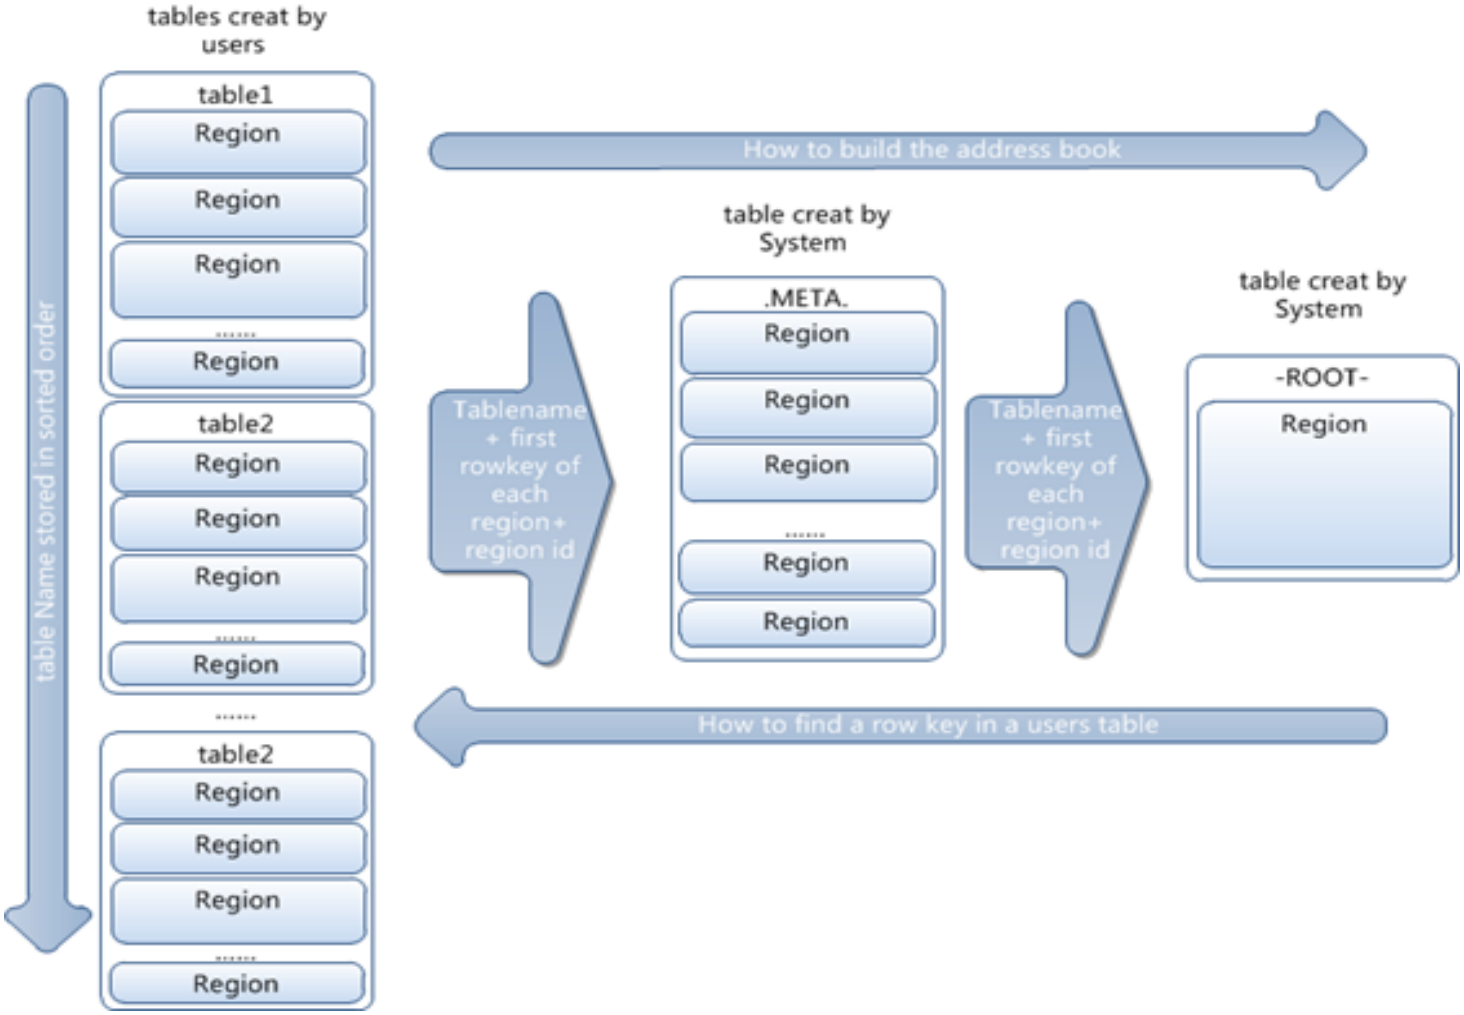

HBase数据存储管理方法

HBase数据记录的查询定位

- 元数据子表采用三级索引结构：

根子表—>用户表的元数据表—>用户表

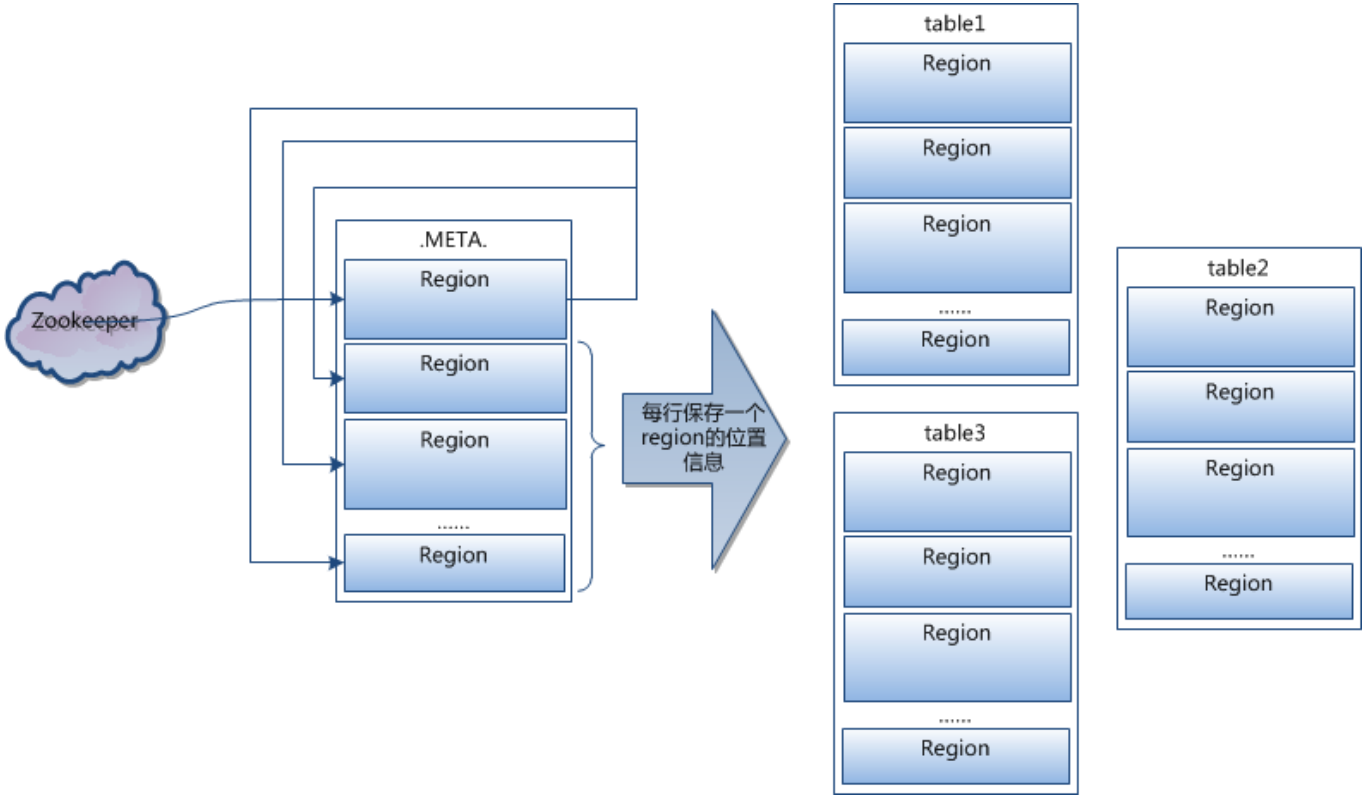

2. HBase基本操作与编程方法

Hbase shell 操作

- HBase shell常用的操作命令有
  - Create
  - Describe
  - Disable
  - enable,drop,list,scan,put,get,delete,deleteall,count,status等
  - 通过help可以看到详细的用法。

HBase Shell操作

- 我们建立如下的表以及数据 table:students

ID	Description		Courses			Home
	Name	Height	Chinese	Math	Physics	Province
001	Li Lei	176	80	90	95	Zhe Jiang
002	Han Meimei	183	88	77	66	Bei Jing
003	Xiao Ming	162	90	90	90	Shang Hai

创建表格与列举表格

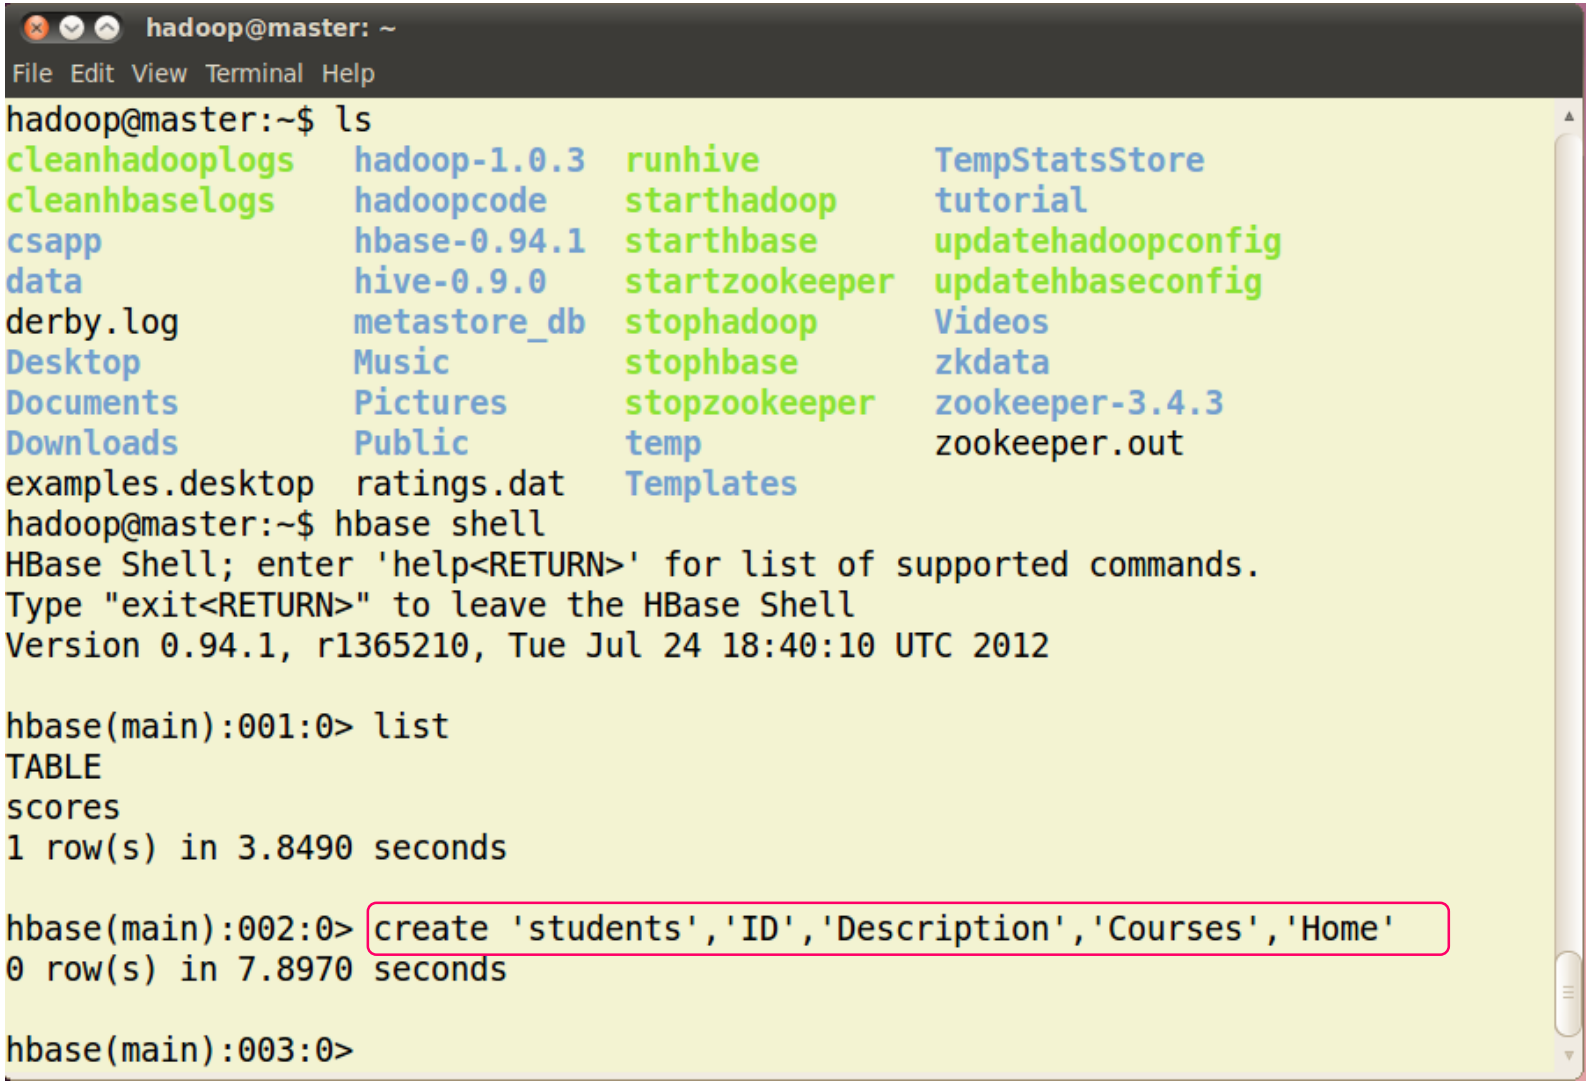
hadoop@master: ~
File Edit View Terminal Help
hadoop@master:~$ ls
cleanhadooplogs hadoop-1.0.3 runhive TempStatsStore
cleanhbaselogs hadoopcode starthadoop tutorial
csapp hbase-0.94.1 starthbase updatehadoopconfig
data hive-0.9.0 startzookeeper updatehbaseconfig
derby.log metastore_db stophadoop Videos
Desktop Music stophbase zkdata
Documents Pictures stopzookeeper zookeeper-3.4.3
Downloads Public temp zookeeper.out
examples.desktop ratings.dat Templates
hadoop@master:~$ hbase shell
HBase Shell; enter 'help<RETURN>' for list of supported commands.
Type "exit<RETURN>" to leave the HBase Shell
Version 0.94.1, r1365210, Tue Jul 24 18:40:10 UTC 2012
hbase(main):001:0> list
TABLE
scores
1 row(s) in 3.8490 seconds
hbase(main):002:0> create 'students','ID','Description','Courses','Home'
0 row(s) in 7.8970 seconds
hbase(main):003:0>

插入数据

```
hadoop@master: ~
File  Edit  View  Terminal  Help
Documents          Pictures      stopzookeeper   zookeeper-3.4.3
Downloads          Public        temp            zookeeper.out
examples.desktop   ratings.dat   Templates
hadoop@master:~$ hbase shell
HBase Shell; enter 'help<RETURN>' for list of supported commands.
Type "exit<RETURN>" to leave the HBase Shell
Version 0.94.1, r1365210, Tue Jul 24 18:40:10 UTC 2012

hbase(main):001:0> list
TABLE
scores
1 row(s) in 3.8490 seconds

hbase(main):002:0> create 'students','ID','Description','Courses','Home'
0 row(s) in 7.8970 seconds

hbase(main):003:0> put 'students','001','Description:Name','Li Lei'
0 row(s) in 0.4350 seconds

hbase(main):004:0> put 'students','001','Description:Height','176'
0 row(s) in 0.0280 seconds

hbase(main):005:0> put 'students','001','Course:Chinese','80'
```

显示描述表信息

```
hadoop@master: ~
File  Edit  View  Terminal  Help
 SSION => 'NONE', MIN_VERSIONS => '0', TTL => '21474
 83647', KEEP_DELETED_CELLS => 'false', BLOCKSIZE =>
  '65536', IN_MEMORY => 'false', ENCODE_ON_DISK => '
 true', BLOCKCACHE => 'true'}]}
1 row(s) in 0.1260 seconds

hbase(main):042:0> list
TABLE
scores
students
2 row(s) in 0.0810 seconds

hbase(main):043:0> describe 'students'
DESCRIPTION                                                          ENABLED
 {NAME => 'students', FAMILIES => [{NAME => 'Courses', DATA_BLOCK_ENCODIN true
 G => 'NONE', BLOOMFILTER => 'NONE', REPLICATION_SCOPE => '0', VERSIONS =
 > '3', COMPRESSION => 'NONE', MIN_VERSIONS => '0', TTL => '2147483647',
 KEEP_DELETED_CELLS => 'false', BLOCKSIZE => '65536', IN_MEMORY => 'false
 ', ENCODE_ON_DISK => 'true', BLOCKCACHE => 'true'}, {NAME => 'Descriptio
 n', DATA_BLOCK_ENCODING => 'NONE', BLOOMFILTER => 'NONE', REPLICATION_SC
 OPE => '0', VERSIONS => '3', COMPRESSION => 'NONE', MIN_VERSIONS => '0',
  TTL => '2147483647', KEEP_DELETED_CELLS => 'false', BLOCKSIZE => '65536
 ', IN_MEMORY => 'false', ENCODE_ON_DISK => 'true', BLOCKCACHE => 'true'}
 , {NAME => 'Home', DATA_BLOCK_ENCODING => 'NONE', BLOOMFILTER => 'NONE',
  REPLICATION_SCOPE => '0', VERSIONS => '3', COMPRESSION => 'NONE', MIN_V
 ERSIONS => '0', TTL => '2147483647', KEEP_DELETED_CELLS => 'false', BLOC
 KSIZE => '65536', IN_MEMORY => 'false', ENCODE_ON_DISK => 'true', BLOCKC
 ACHE => 'true'}, {NAME => 'ID', DATA_BLOCK_ENCODING => 'NONE', BLOOMFILT
 ER => 'NONE', REPLICATION_SCOPE => '0', VERSIONS => '3', COMPRESSION =>
 'NONE', MIN_VERSIONS => '0', TTL => '2147483647', KEEP_DELETED_CELLS =>
 'false', BLOCKSIZE => '65536', IN_MEMORY => 'false', ENCODE_ON_DISK => '
 true', BLOCKCACHE => 'true'}]}
1 row(s) in 0.0780 seconds

hbase(main):044:0>
```

输入数据与扫描数据

```
hadoop@master: ~
File  Edit  View  Terminal  Help
hbase(main):051:0> put 'students','002','Home:Province','Bei Jing'
0 row(s) in 0.0420 seconds

hbase(main):052:0> put 'students','003','Home:Province','Shang Hai'
0 row(s) in 0.0270 seconds

hbase(main):053:0> put 'students','002','Description:Name','Han Meimei'
0 row(s) in 0.0470 seconds

hbase(main):054:0> put 'students','002','Description:Height','183'
0 row(s) in 0.0360 seconds

hbase(main):055:0> put 'students','003','Description:Height','162'
0 row(s) in 0.0240 seconds

hbase(main):056:0> put 'students','003','Description:Name','Xiao Ming'
0 row(s) in 0.0190 seconds

hbase(main):057:0> scan 'students'
ROW                          COLUMN+CELL
 001                         column=Courses:Chinese, timestamp=1351776664719, value=80
 001                         column=Courses:Math, timestamp=1351776678749, value=90
 001                         column=Courses:Physics, timestamp=1351776693609, value=95
 001                         column=Description:Height, timestamp=1351776295307, value=176
 001                         column=Description:Name, timestamp=1351776277573, value=Li Lei
 001                         column=Home:Province, timestamp=1351776717090, value=Zhe Jiang
 002                         column=Description:Height, timestamp=1351776794960, value=183
 002                         column=Description:Name, timestamp=1351776780963, value=Han Meimei
 002                         column=Home:Province, timestamp=1351776742893, value=Bei Jing
 003                         column=Description:Height, timestamp=1351776806923, value=162
 003                         column=Description:Name, timestamp=1351776822022, value=Xiao Ming
 003                         column=Home:Province, timestamp=1351776757867, value=Shang Hai
3 row(s) in 0.2140 seconds

hbase(main):058:0>
```

限制列进行扫描

```
hbase(main):098:0* scan 'students',{COLUMNS=>'Courses:'}
ROW                           COLUMN+CELL
 001                          column=Courses:Chinese, timestamp=1351776664719, value=80
 001                          column=Courses:Math, timestamp=1351776678749, value=90
 001                          column=Courses:Physics, timestamp=1351776693609, value=95
 002                          column=Courses:Chinese, timestamp=1351776979636, value=88
 002                          column=Courses:Math, timestamp=1351776989455, value=77
 002                          column=Courses:Physics, timestamp=1351776999603, value=66
 003                          column=Courses:Chinese, timestamp=1351776946110, value=90
 003                          column=Courses:Math, timestamp=1351776952592, value=90
 003                          column=Courses:Physics, timestamp=1351776963651, value=90
3 row(s) in 0.1560 seconds

hbase(main):099:0>
```

HBase中的disable和enable

- disable和enable都是HBase中比较常见的操作，很多对table的修改都需要表在disable的状态下才能进行
- disable ‘students'将表students的状态更改为disable的时候，HBase会在zookeeper中的table结点下做记录
- 在zookeeper记录下修改该表的同时，还会将表的region全部下线，region为offline状态
- enable的过程和disable相反，会把表的所有region上线，并删除zookeeper下的标志。如果在enable前，META中有region的server信息，那么此时会在该server上将该region 上线；如果没有server的信息，那么此时还要随机选择一台机器作为该region的server

HBase的Java编程

- HBase Java编程接口概述HBaseConfiguration

HBaseConfiguration是每一个hbase client都会使用到的对象，它代表的是HBase配置信息。

默认的构造方式会尝试从hbase-default.xml和hbase-site.xml中读取配置。如果classpath没有这两个文件，就需要你自己设置配置。

配置Java代码示例：

```
Configuration HBASE_CONFIG = new Configuration();
HBASE_CONFIG.set("hbase.zookeeper.quorum", "zkServer");
HBASE_CONFIG.set("hbase.zookeeper.property.clientPort", "2181" );
HBaseConfiguration cfg = new BaseConfiguration(HBASE_CONFIG);
```

HBase的Java编程:创建表

- 创建表是通过HBaseAdmin对象来操作的。HBaseAdmin负责表的META信息处理。HBaseAdmin提供了createTable这个方法：
  public void createTable(HTableDescriptor desc)

  HTableDescriptor 代表的是表的schema

  HColumnDescriptor 代表的是column的schema

Java代码示例：

```
HBaseAdmin hAdmin = new HBaseAdmin(hbaseConfig);
HTableDescriptor t = new HTableDescriptor(tableName);
t.addFamily(new HColumnDescriptor("f1"));
t.addFamily(new HColumnDescriptor("f2"));
t.addFamily(new HColumnDescriptor("f3"));
t.addFamily(new HColumnDescriptor("f4"));
hAdmin.createTable(t);
```

HBase的Java编程:插入数据

- HTable通过put方法来插入数据，可以传递单个批Put对象或者List put对象来分别实现单条插入和批量插入

➢ **Put对象的常用的方法：**

```
public static void addData (String tableName, String rowKey,
                                    String family, String qualifier, String value)
                    throws Exception
{  try {
          HTable table = new HTable(conf, tableName);
          Put put = new Put(Bytes.toBytes(rowKey));
          put.add(Bytes.toBytes(family), Bytes.toBytes(qualifier),
                    Bytes.toBytes(value));
          table.put(put);
          System.out.println("insert recored success!");
        } catch (IOException e) {   e.printStackTrace();   }
}
```

HBase的Java编程:插入数据

- HTable通过put方法来插入数据，可以传递单个批Put对象或者List put对象来分别实现单条插入和批量插入

- **setTimeStamp:**指定所有**cell**默认的**timestamp,**如果一个**Cell**没有指定**timestamp,**就会用到这个值。如果没有调用，**HBase**会将当前时间作为未指定**timestamp**的**cell**的**timestamp.**
- **setWriteToWAL: WAL**是**Write Ahead Log**的缩写，指的是**HBase**在插入操作前是否写**Log**。默认是打开，关掉会提高性能，但是如果系统出现故障**(**负责插入的**Region Server**挂掉**)**，数据可能会丢失。

- 另外**HTable**也有两个方法也会影响插入的性能
- **setAutoFlash: AutoFlush**指的是在每次调用**HBase**的**Put**操作时，是否提交到**HBase Server**。默认是**true,**每次会提交。如果此时是单条插入，就会有更多的**I/O,**从而降低性能**.**
- **setWriteBufferSize: Write Buffer Size**在**AutoFlush**为**false**的时候起作用，默认是**2MB,**也就是当插入数据超过**2MB,**就会自动提交到**Server**

HBase的Java编程:删除表

- 删除表也通过HBaseAdmin来操作，删除表之前首先要disable表。这是一个非常耗时的操作，所以不建议频繁删除表。disableTable和deleteTable分别用来disable和delete表

Java代码示例：

```
HBaseAdmin hAdmin = new HBaseAdmin(hbaseConfig);
if (hAdmin.tableExists(tableName)) {
  hAdmin.disableTable(tableName);
  hAdmin.deleteTable(tableName);
}
```

HBase的Java编程:查询数据

- 查询分为单条随机查询和批量查询
  - 单条查询是通过rowkey在table中查询某一行的数据。HTable提供了get方法来完成单条查询。
  - 批量查询是通过制定一段rowkey的范围来查询。HTable提供了个getScanner方法来完成批量查询。

Java代码示例：

```
Scan s = new Scan();
s.setMaxVersions();
ResultScanner ss = table.getScanner(s);
for(Result r:ss){
    System.out.println(new String(r.getRow()));
    for(KeyValue kv:r.raw()){
       System.out.println(new String(kv.getColumn()));
    }
}
```

HBase的Java编程:删除数据

- HTable 通过delete方法来删除数据: delete(final Delete delete)

Delete常用方法：

deleteFamily或deleteColumns:

指定要删除的family或者column的数据。如果不调用任何这样的方法，将会删除整行

```
HTable table = new HTable(hbaseConfig, “mytest”);
Delete d = new Delete(“row1″.getBytes());
table.delete(d)
```

HBase的Java编程:切分表

- 参数hbase.hregion.max.filesize指示在当前ReigonServer上单个Reigon的最大存储空间，单个Region超过该值时，这个Region会被自动split成更小的region。

HBaseAdmin提供split方法来将table 进行手工split.

public void split(final String tableNameOrRegionName)

如果提供tableName，那么会将table所有region进行split ;如果提供region Name，那么只会split这个region.

由于split是一个异步操作，并不能确切地控制region的个数。

HBase的Java编程:程序的编写与运行

- 与Hadoop编程类似，在进行HBase Java编程的时候也需要配置相关的类包文件jar文件，在程序执行的时候，还需要给出类库的目录

在开发环境中准备导入jar包：
将HBase目录中的jar包以及lib中的所有jar包都加入

HBase的Java编程:程序的编写与运行

与编写其它Java代码类似，可以通过代码编写

参考例子代码进行代码分析，例子代码演示了数据库的各项操作，包括创建表，插入记录，删除记录，查询等

```
import java.io.IOException;

public class HBaseSample {

    private static Configuration conf =null;

    static {
         conf = HBaseConfiguration.create();
     }

    public static void creatTable(String tableName, String[] familys) throws Exception {
        HBaseAdmin admin = new HBaseAdmin(conf);
        if (admin.tableExists(tableName)) {
            System.out.println("table already exists!");
        } else {
            HTableDescriptor tableDesc = new HTableDescriptor(tableName);
            for(int i=0; i<familys.length; i++){
                tableDesc.addFamily(new HColumnDescriptor(familys[i]));
            }
            admin.createTable(tableDesc);
            System.out.println("create table " + tableName + " ok.");
        }
    }
```

3. Hive基本工作原理

使用Hadoop进行数据分析

- 通过前面的课程知道，很多分析任务可以通过Hadoop集群进行，即可以通过Hadoop集群将任务分布到数百甚至上千个节点中进行分析，通过并行执行降低分析的时间
- 如果原始数据使用数据库形式的话，则需要进行数据的转换，将数据存储到分布式文件系统HDFS中，然后通过MapReduce程序进行分析
- Hadoop通过MapReduce的并行化方式进行并行处理，能够充分利用数目庞大的服务器节点
- 但是，MapReduce是一个底层的编程接口，对于数据分析人员来说，这个编程接口并不是十分友好，还需要进行大量的编程以及调试工作

Hive简介

- Hive可以被认为是一种数据仓库，包括数据的存储以及查询
- Hive包括一个高层语言的执行引擎，类似于SQL的执行引擎
- Hive建立在Hadoop的其它组成部分之上，包括Hive依赖于HDFS进行数据保存，依赖于MapReduce完成查询操作
- Hive最初的开发由Facebook推动，在Facebook内部每天会搜集大量的数据，并需要在这些数据上进行大量分析
- 最初的分析是通过手工的python脚本形式进行
- 数据分析的数量十分巨大，在2006年每天需要分析数十个10GB左右的数据，在2007年增长到大约TB的量级，现在数据分析的数量可能是这个数量的10倍

Hive的应用范围举例

- 日志分析：在互联网公司中，每天会产生大量的日志数据，分析这些日志数据是每天都需要进行的重要工作；日志分析可以优化系统，可以获知用户行为，也可以获知数据的统计信息
- 数据挖掘：通过对结构化数据的挖掘，能够获得原先使用者没有意识到的信息
- 文档索引：可以对一系列文档进行分析，并形成文档的索引结构，不一定是完整的倒排表，可能是关联信息的索引
- 商业智能信息处理：可以对商业信息进行查询分析，从中可以获得一些智能决策的信息
- 即时查询以及数据验证：数据分析人员可能临时需要验证数据的特性，需要查询引擎迅速进行数据统计分析

Hive的组成模块（1）

- Hive的模块非常类似于传统的数据库的模块，下面是Hive的必要组成模块以及对应的功能介绍
- HiveQL：这是Hive的数据查询语言，与SQL非常类似。Hive提供了这个数据查询语言与用户的接口，包括一个shell的接口，可以进行用户的交互以及网络接口与JDBC接口。JDBC接口可以用于编程，与传统的数据库编程类似，使得程序可以直接使用Hive功能而无需更改
- Driver: 执行驱动程序，用以将各个组成部分形成一个有机的执行系统，包括会话的处理，查询获取以及执行驱动

Hive的组成模块（2）

- Compiler：Hive需要一个编译器，将HiveQL语言编译成中间表示，包括对于HiveQL语言的分析，执行计划的生成以及优化等工作
- Execution Engine：执行引擎，在Driver的驱动下，具体完成执行操作，包括MapReduce执行，或者HDFS操作，或者元数据操作
- Metastore：用以存储元数据：存储操作的数据对象的格式信息，在HDFS中的存储位置的信息以及其他的用于数据转换的信息SerDe等

Hive的系统结构

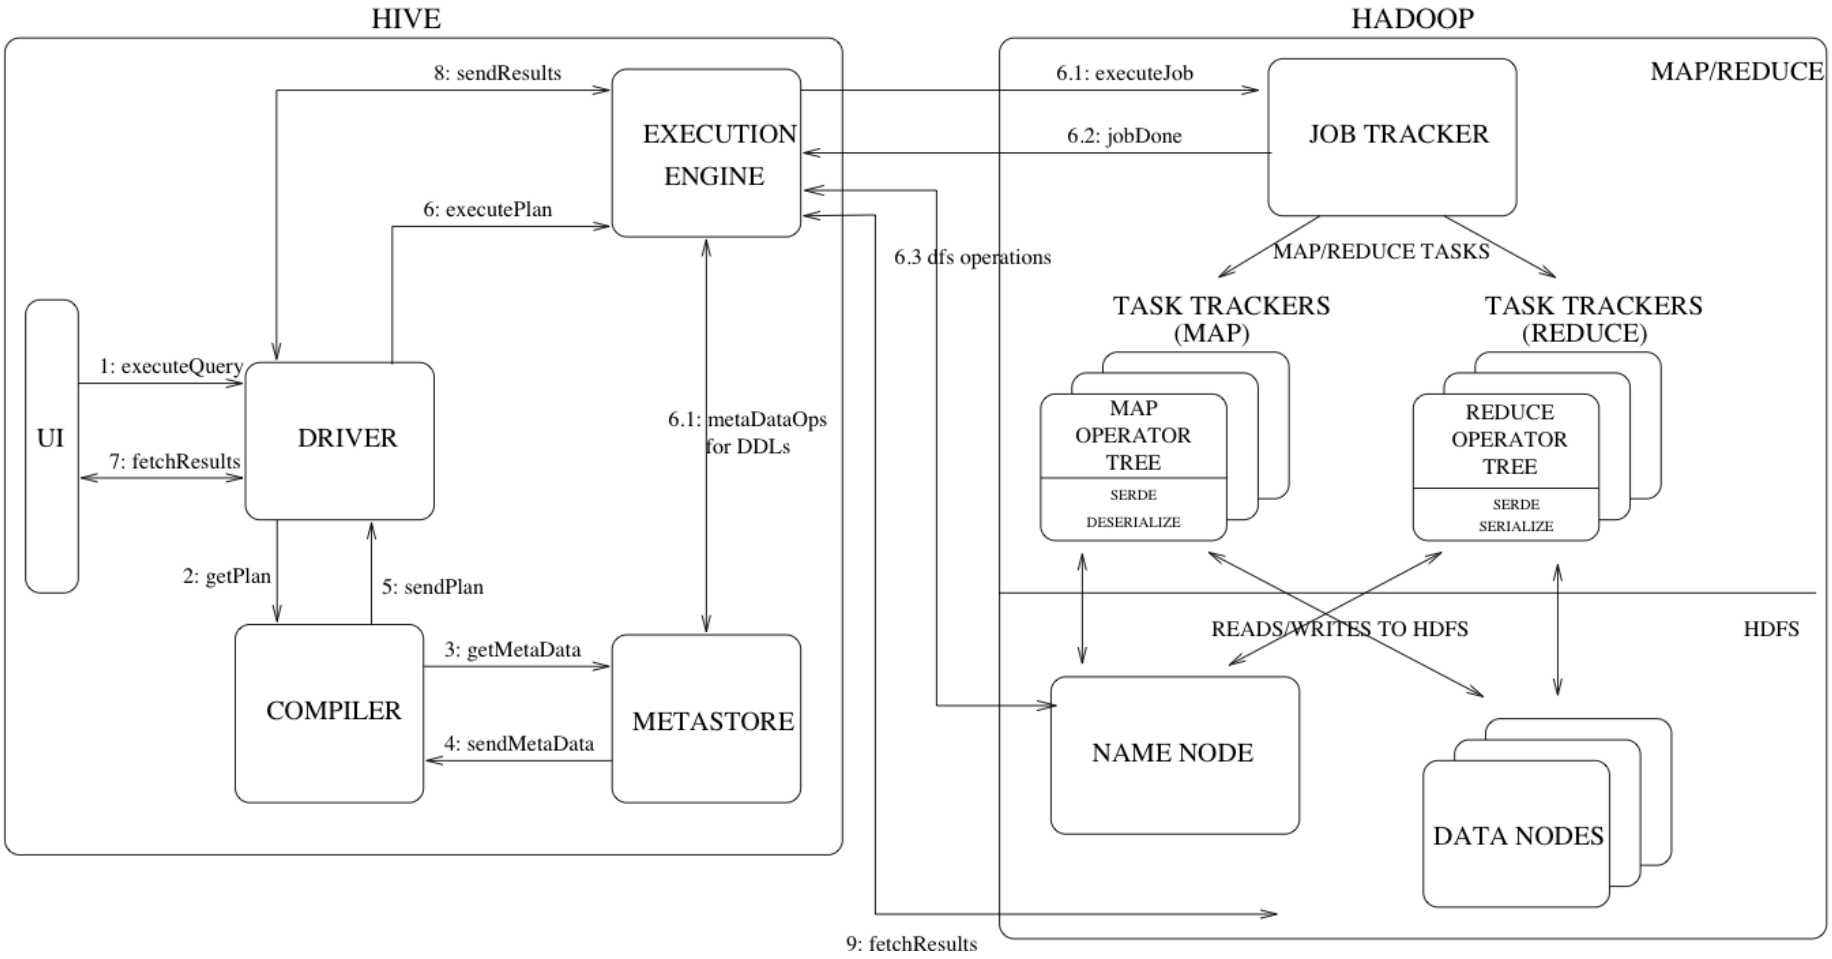
HIVE
HADOOP
MAP/REDUCE
8: sendResults
EXECUTION ENGINE
6.1: executeJob
6.2: jobDone
JOB TRACKER
6: executePlan
6.3 dfs operations
MAP/REDUCE TASKS
TASK TRACKERS (MAP)
TASK TRACKERS (REDUCE)
UI
1: executeQuery
7: fetchResults
DRIVER
6.1: metaDataOps for DDLs
MAP OPERATOR TREE
SERDE DESERIALIZE
REDUCE OPERATOR TREE
SERDE SERIALIZE
2: getPlan
5: sendPlan
READS/WRITES TO HDFS
HDFS
3: getMetaData
COMPILER
METASTORE
4: sendMetaData
NAME NODE
DATA NODES
9: fetchResults

Hive的数据模型

- 每一个类似于数据库的系统都首先需要定义一个数据模型，然后才是在这个数据模型之上的各种操作
- Tables：Hive的数据模型由数据表组成

  数据表中的列是有类型的（int, float, string, data, boolean）

  也可以是复合的类型，如list: map （类似于JSON形式的数据）
- Partitions：数据表可以按照一定的规则进行划分Partition

  例如，通过日期的方式将数据表进行划分
- Buckets：数据存储的桶

  在一定范围内的数据按照Hash的方式进行划分（这对于数据的抽样以及对于join的优化很有意义）

元数据存储：Metastore

- 在Hive中由一系列的数据表格组成一个命名空间，关于这个命名空间的描述信息会保存在Metastore的空间中
- 元数据使用SQL的形式存储在传统的关系数据库中，因此可以使用任意一种关系数据库，例如Derby(apache的关系数据库实现)，MySQL以及其他的多种关系数据库存储方法
- 在数据库中，保存最重要的信息是有关数据库中的数据表格描述，包括每一个表的格式定义，列的类型，物理的分布情况，数据划分情况等

数据的物理分布情况

- Hive在HDFS中有固定的位置，通常被放置在HDFS的如下目录中：

  /home/hive/warehouse

- 每个数据表被存放在warehouse的子目录中

  进一步来说，数据划分Partition、数据桶Buckets形成了数据表的子目录

- 数据可能以任意一种形式存储，例如：
  - 使用分隔符的文本文件，或者是SequenceFile
  - 使用用户自定义的SerDe，则可以定义任意格式的文件

Hive系统的配置

- 要想Hive使用HDFS进行数据仓库的存储，使用MapReduce进行HQL语言的执行，需要进行相应的配置。首先，需要创建Hive的配置文件hive-site.xml(注意，Hive安装包中包含一个配置文件模板－hive-default.xml.template）
  - fs.default.name用以告知Hive对应的HDFS文件系统的名字节点在什么位置
  - mapred.job.tracker用以告知Hive对应的MapReduce处理系统的任务管理器在什么位置
- 通过上面两点的配置，就可以让Hive系统与对应的HDFS以及MapReduce进行交互，完成数据的存取以及查询的操作

4. Hive基本操作示例

启动Hive的命令行界面shell

- 完成Hive系统的合适配置之后，打开任意一个命令行界面，执行下面的命令就可以启动hive的界面
- $cd /hive/install/directory 进入hive的安装目录
- $bin/hive 如果已经将hive加入到执行路径，则可以直接执行hive即可
- 执行成功的话，我们就可以看到hive的主界面

  hive>
- 等待用户输入查询命令

创建数据表的命令

- 显示所有的数据表

  hive> show tables;

- 创建一个表，这个表包括两列，分别是整数类型以及字符串类型，使用文本文件表达，数据域之间的分隔符为\t

  hive> create table shakespeare (freq int, word string) row format delimited fields terminated by '\t' stored as textfile;

- 显示所创建的数据表的描述，即创建时候对于数据表的定义

  hive> describe shakespeare；

装入数据

- 数据装入到Hive中

  hive> load data inpath “shakespeare_freq” into table shakespeare;

SELECTS and FILTERS

- hive> select * from shakespeare limit 10;
- hive> select * from shakespeare
  where freq > 100 sort by freq asc limit 10;
- hive> SELECT a.foo FROM invites a WHERE a.ds='2008-08-15';
- hive> INSERT OVERWRITE DIRECTORY '/tmp/hdfs_out'
  SELECT a.* FROM invites a WHERE a.ds='2008-08-15';
- hive> INSERT OVERWRITE LOCAL DIRECTORY '/tmp/local_out'
  SELECT a.* FROM pokes a;

Group By

- hive> INSERT OVERWRITE TABLE events
  SELECT a.bar, count(*)
  FROM invites a
  WHERE a.foo > 0 GROUP BY a.bar;

Join

- hive> SELECT t1.bar, t1.foo, t2.foo
  FROM pokes t1 JOIN invites t2 ON t1.bar = t2.bar;

Hive总结

- Hive提供了一种类似于SQL的查询语言，使得其能够用于用户的交互查询
- 与传统的数据库类似，Hive提供了多个数据表之间的联合查询，能够完成高效的多个数据表之间的查询
- 通过底层执行引擎的工作，Hive将SQL语言扩展到很大的查询规模

实验3： Hive-MyJoin

- 实验内容与要求

- 1. 使用MapReduce完成两张表的join操作。
- 2. 实验数据在“本科教学支撑平台 cslabcms”的实验3目录下。
- 3. 输入数据为order.txt和product.txt，在Hive中新建表，若表存在则提示后删除重建，并在新建的表中插入合并后的数据，表名：order，列族：order 。
- 4. product.txt文件从左往右分别为“商品ID”、“商品名称”，“商品单价”。order.txt文件分别为“订单日期”、“商品ID”、“购买数量”。合并两个文件数据，并存入到Hive中，每行的行键为“订单ID”。
- 5. 要求程序跑完后可通过Hive查看生成的表。

实验3： Hive-MyJoin

- 实验内容与要求

- 实验结果提交：要求书写一个实验报告，其中包括：
  1. 实验设计说明，包括主要设计思路、算法设计、程序和各个类的设计说明
  2. 源程序， 执行程序
  3. 实验输出结果开头部分的屏幕拷贝
  4. 运行结果文件内容截图
  5. 实验报告文件命名规则： MPLab3--组号-组长姓名.doc
  6. 实验报告提交至：本科教学支撑平台 http://cslabcms.nju.edu.cn/
  - 实验完成时间： 2020年4月30日

Thanks !

Backups

行主键

- 行主键row key是用来检索记录的主键。这样的话，访问HBase table中的行，有三种方式：1 通过单个row key访问；2 通过row key的范围range来访问；3 全表扫描
- 行键 (Row key)可以是任意字符串(最大长度是 64KB，实际应用中长度一般为 10-100bytes)，在HBase内部，row key保存为字节数组。
- 存储时，数据按照Row key的字典序(byte order)排序存储。这样的话，设计key时，要充分排序存储这个特性，将经常一起读取的行存储放到一起。(空间局部性)
- 字典序对int排序的结果是1,10,100,11,12,13,14,15,16,17,18,19,2,20,21,…,9,91,92,93,94,95,96,97,98,99。要保持整形的自然序，行键必须用0作左填充。
- 行的一次读写是原子操作 (不论一次读写多少列)。这样的设计兼顾了用户可以理解在一行中的读写行为以及设计上的可扩展性

列族

- 列族的设计与传统数据库中的列不一致
- 与BigTable中的模式一样，hbase表中的每个列，都归属与某个列族。列族是表的schema的一部分，必须在使用表之前定义。列名都以列族作为前缀。例如 *courses:history*， *courses:math* *都属于courses* 这个列族。
- 访问控制、磁盘和内存的使用统计都是在列族层面进行的。实际应用中，列族上的控制权限能帮助管理不同类型的应用：允许一些应用可以添加新的基本数据、一些应用可以读取基本数据并创建继承的列族、一些应用则只允许浏览数据（甚至可能因为隐私的原因不能浏览所有数据）

时间戳timestamp

- HBase中通过row和columns确定的为一个存贮单元称为单元格cell。每个 cell都保存着同一份数据的多个版本。版本通过时间戳来索引。时间戳的类型是 64位整型。时间戳可以由HBase(在数据写入时自动)赋值，此时时间戳是精确到毫秒的当前系统时间。时间戳也可以由客户显式赋值。如果应用程序要避免数据版本冲突，就必须自己生成具有唯一性的时间戳。每个cell中，不同版本的数据按照时间倒序排序，即最新的数据排在最前面。
- 为了避免数据存在过多版本造成的的管理 (包括存贮和索引)负担，HBase提供了两种数据版本回收方式。一是保存数据的最后n个版本，二是保存最近一段时间内的版本（比如最近七天）。用户可以针对每个列族进行设置。

HBase存储格式

- HBase中的所有数据文件都存储在Hadoop HDFS文件系统上，主要包括上述提出的两种文件类型：
- 1.HFile， HBase中KeyValue数据的存储格式，HFile是Hadoop的二进制格式文件，实际上StoreFile就是对HFile做了轻量级包装，即StoreFile底层就是HFile
- 2.HLogFile，HBase中WAL（Write Ahead Log） 的存储格式，物理上是Hadoop的Sequence File

HFile

- 首先HFile文件是不定长的，长度固定的只有其中的两块：Trailer和FileInfo。Trailer中有指针指向其他数据块的起始点。File Info中记录了文件的一些Meta信息，例如：AVG_KEY_LEN, AVG_VALUE_LEN, LAST_KEY, COMPARATOR, MAX_SEQ_ID_KEY等。Data Index和Meta Index块记录了每个Data块和Meta块的起始点。
- Data Block是HBase I/O的基本单元，为了提高效率，HRegionServer中有基于LRU的Block Cache机制。每个Data块的大小可以在创建一个Table的时候通过参数指定，大号的Block有利于顺序Scan，小号Block利于随机查询。每个Data块除了开头的Magic以外就是一个个KeyValue对拼接而成, Magic内容就是一些随机数字，目的是防止数据损坏。后面会详细介绍每个KeyValue对的内部构造。

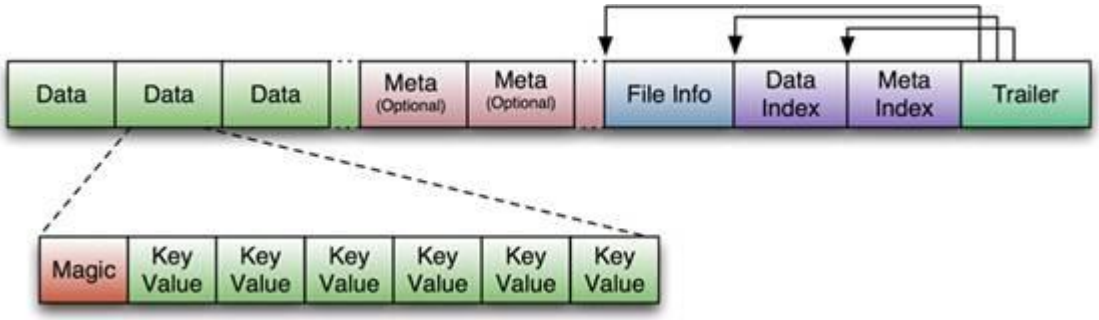

HFile文件的格式描述（1）

- Data Block 段–保存表中的数据，这部分可以被压缩
- Meta Block 段 (可选的)–保存用户自定义的kv对，可以被压缩。
- File Info 段–HFile的元信息，不被压缩，用户也可以在这一部分添加自己的元信息。
- Data Block Index 段–Data Block的索引。每条索引的key是被索引的block的第一条记录的key。
- Meta Block Index段 (可选的)–Meta Block的索引。
- Trailer–这一段是定长的。保存了每一段的偏移量，读取一个HFile时，会首先读取Trailer，Trailer保存了每个段的起始位置(段的Magic Number用来做安全check)，然后，DataBlock Index会被读取到内存中，这样，当检索某个key时，不需要扫描整个HFile，而只需从内存中找到key所在的block，通过一次磁盘io将整个block读取到内存中，再找到需要的key。DataBlock Index采用LRU机制淘汰。

HFile文件的格式（2）

- HFile的Data Block，Meta Block通常采用压缩方式存储，压缩之后可以大大减少网络IO和磁盘IO，随之而来的开销当然是需要花费cpu进行压缩和解压缩。目标Hfile的压缩支持两种方式：Gzip，Lzo。
- HLog(WAL log):WAL 意为Write ahead log，用来做灾难恢复只用，Hlog记录数据的所有变更,一旦数据修改，就可以从log中进行恢复。
- 每个Region Server维护一个Hlog,而不是每个Region一个。这样不同region(来自不同table)的日志会混在一起，这样做的目的是不断追加单个文件相对于同时写多个文件而言，可以减少磁盘寻址次数，因此可以提高对table的写性能。带来的麻烦是，如果一台region server下线，为了恢复其上的region，需要将region server上的log进行拆分，然后分发到其它region server上进行恢复。
- HLog文件就是一个普通的Hadoop Sequence File，Sequence File 的Key是HLogKey对象，HLogKey中记录了写入数据的归属信息，除了table和region名字外，同时还包括 sequence number和timestamp，timestamp是”写入时间”，sequence number的起始值为0，或者是最近一次存入文件系统中sequence number。HLog Sequece File的Value是HBase的KeyValue对象，即对应HFile中的KeyValue，

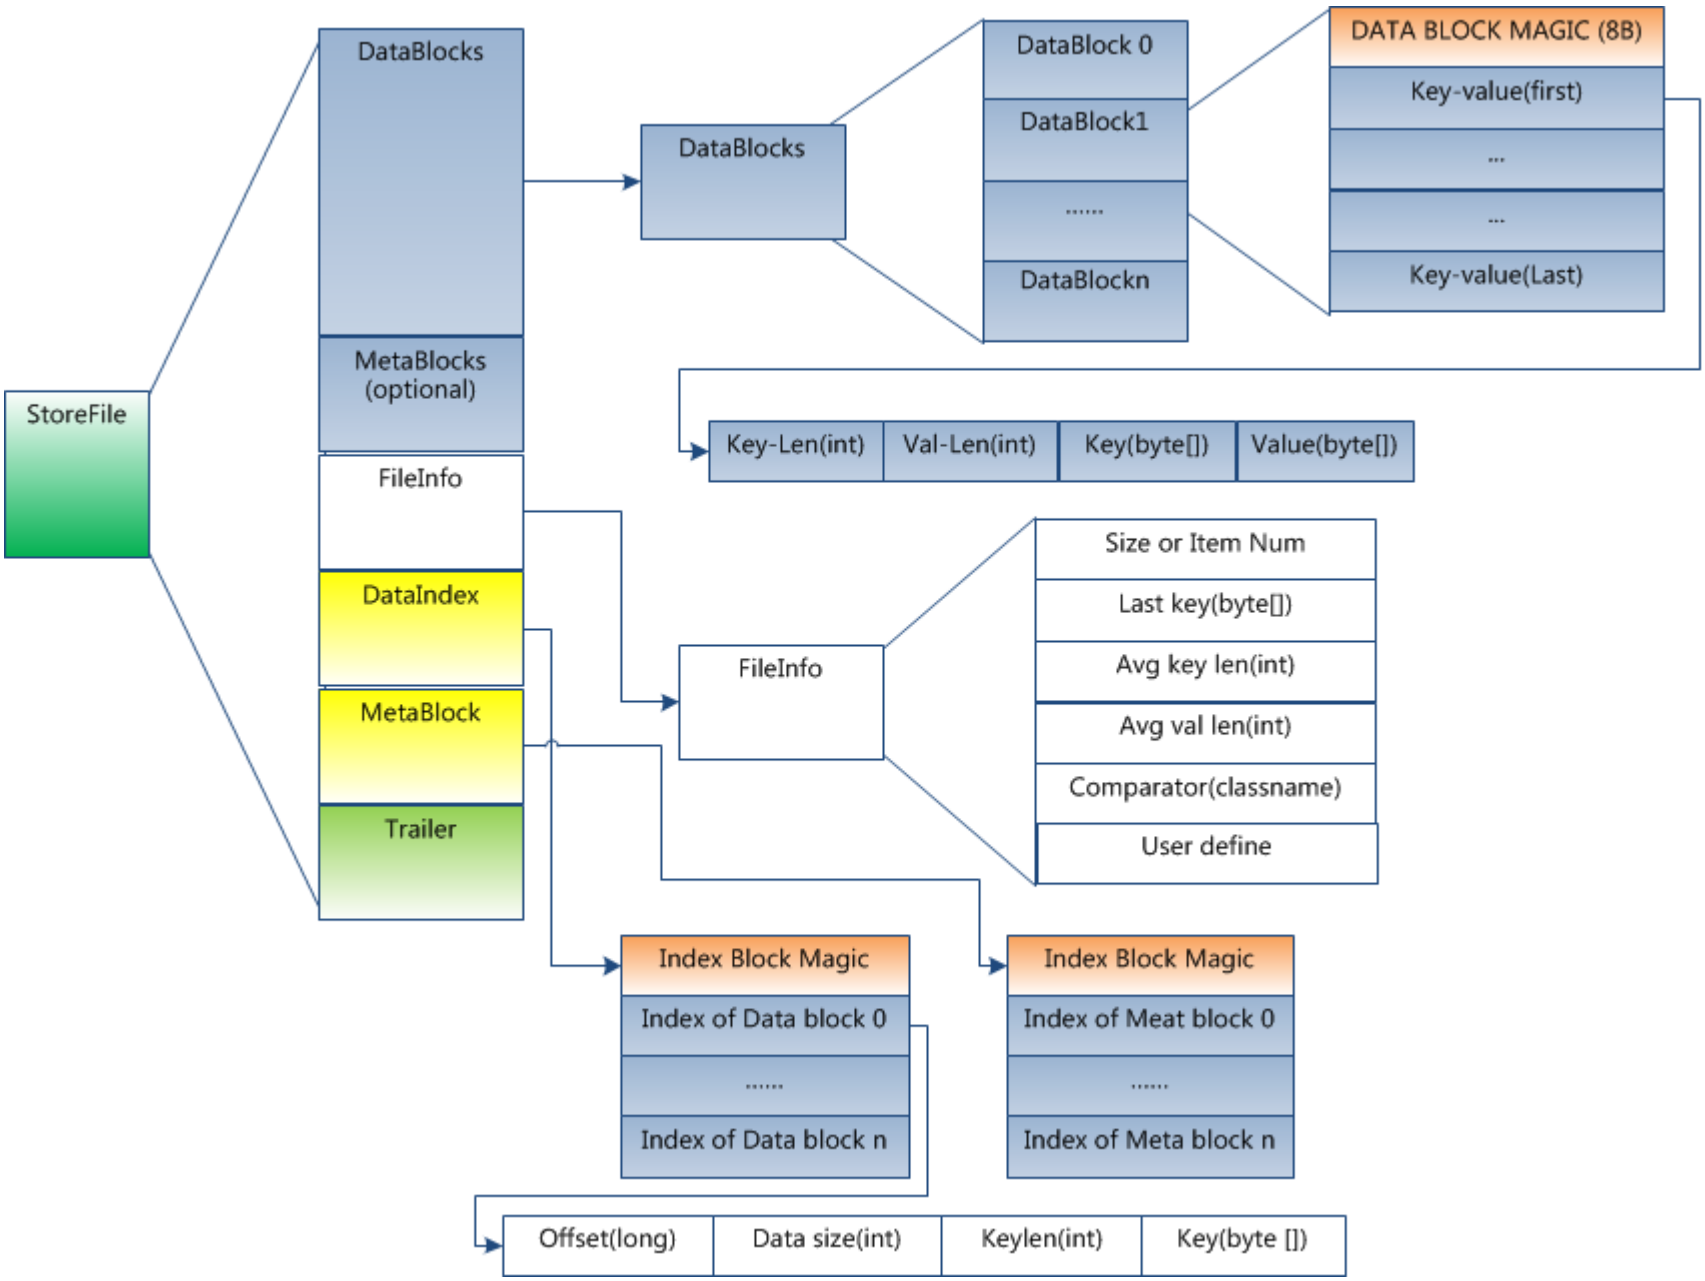
StoreFile
DataBlocks
MetaBlocks (optional)
FileInfo
DataIndex
MetaBlock
Trailer
DataBlocks
DataBlock 0
DataBlock1
.....
DataBlockn
DATA BLOCK MAGIC (8B)
Key-value(first)
...
...
Key-value(Last)
Key-Len(int)
Val-Len(int)
Key(byte[])
Value(byte[])
FileInfo
Size or Item Num
Last key(byte[])
Avg key len(int)
Avg val len(int)
Comparator(classname)
User define
Index Block Magic
Index of Data block 0
.....
Index of Data block n
Index Block Magic
Index of Meat block 0
.....
Index of Meta block n
Offset(long)
Data size(int)
Keylen(int)
Key(byte [])

Trailer部分的格式

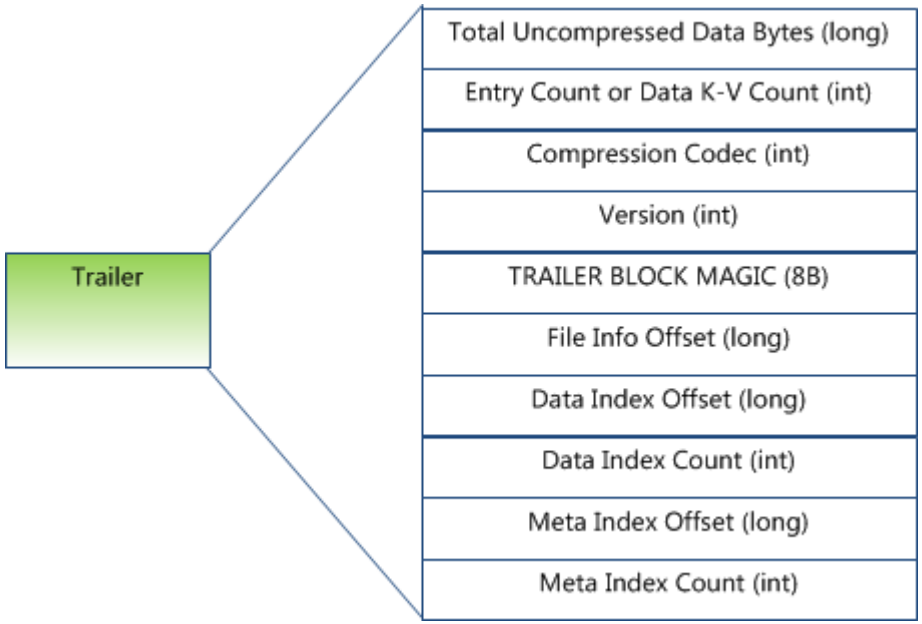

HLogFile

- 其实HLog文件就是一个普通的Hadoop Sequence File，Sequence File 的Key是HLogKey对象，HLogKey中记录了写入数据的归属信息，除了table和region名字外，同时还包括 sequence number和timestamp，timestamp是“写入时间”，sequence number的起始值为0，或者是最近一次存入文件系统中sequence number。
- HLog Sequece File的Value是HBase的KeyValue对象，即对应HFile中的KeyValue

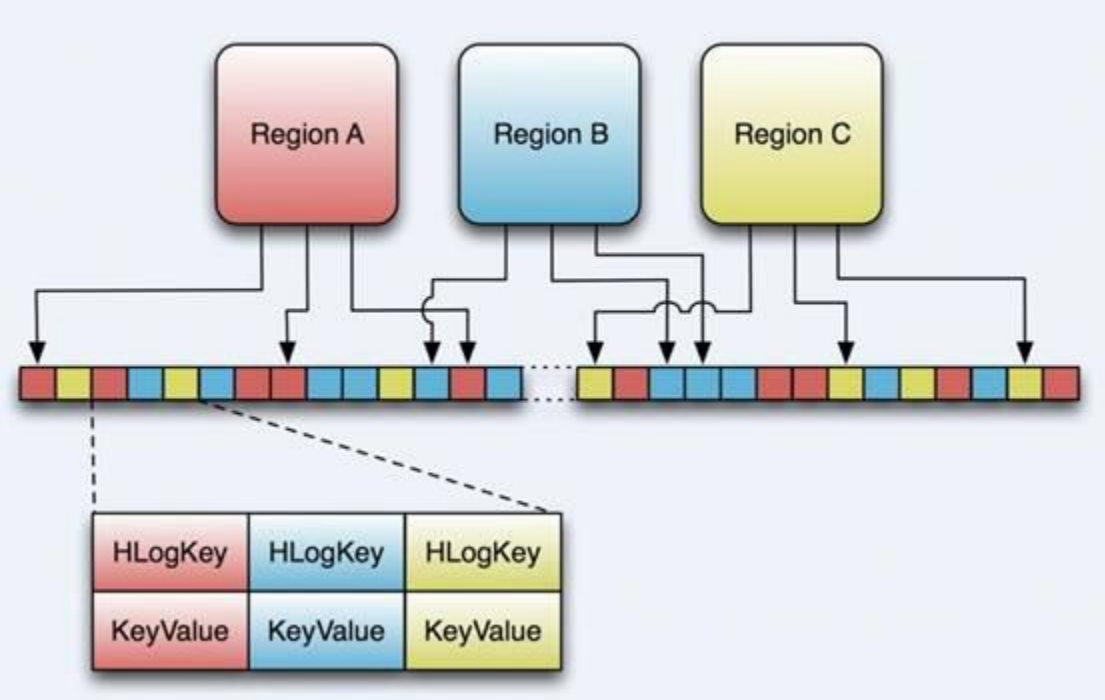

HBase的运行组成

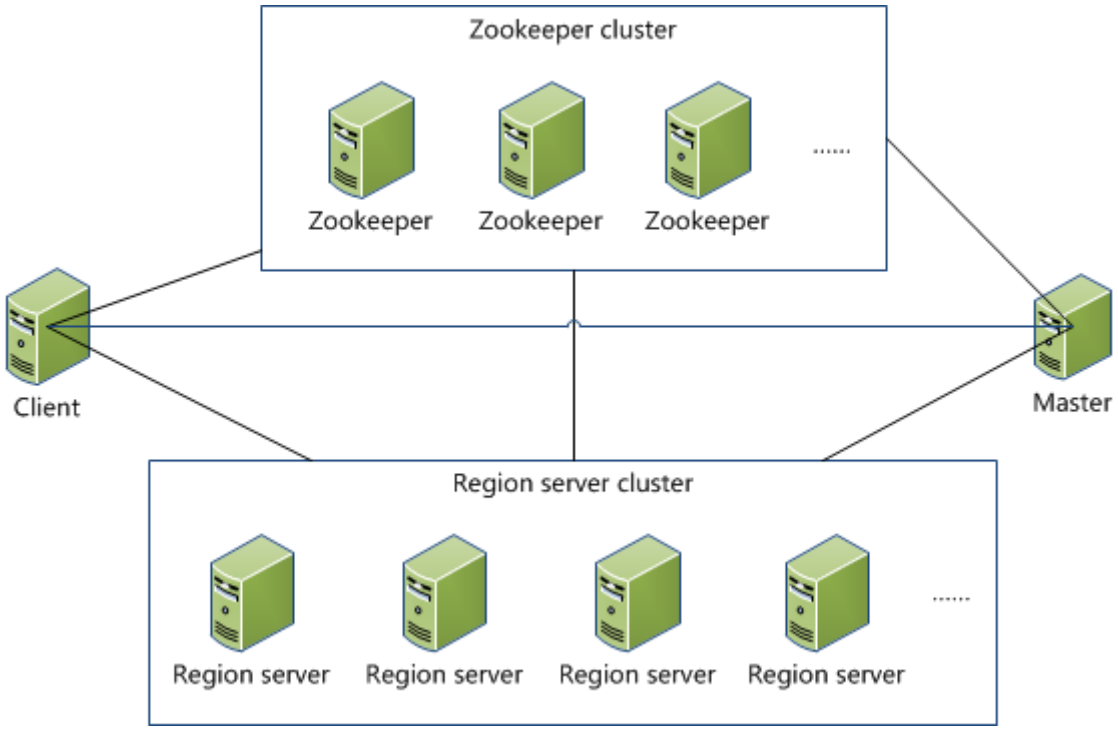
Zookeeper cluster
Zookeeper
Zookeeper
Zookeeper
.....
Client
Master
Region server cluster
Region server
Region server
Region server
Region server
.....

Hive客户端

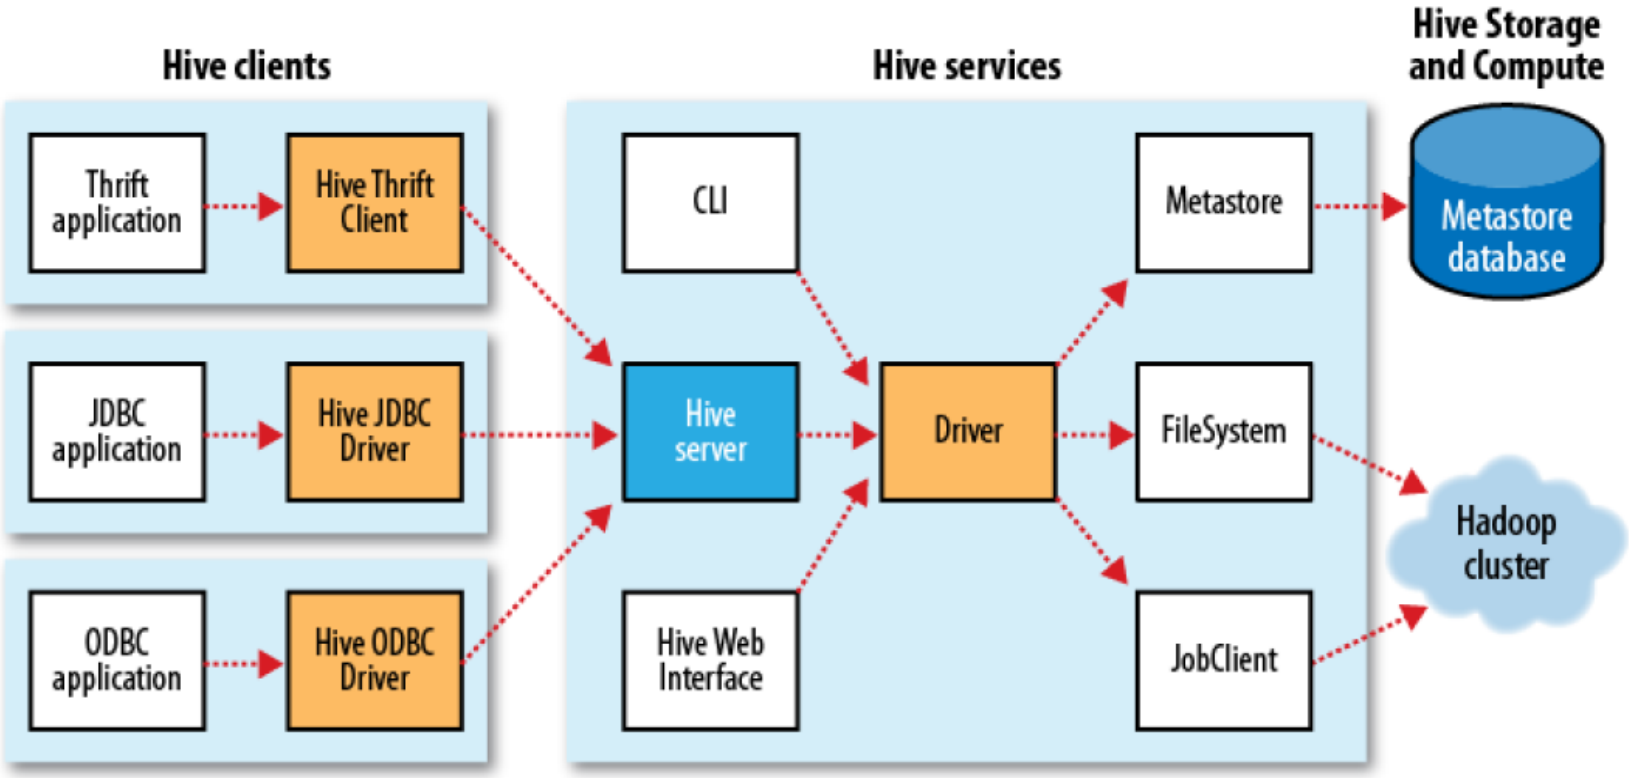

通过将Hive运行为服务器hive –service hiveserver可以启动一个服务，而后可以通过不同的客户端连接到这个服务去访问Hive提供的功能

Hive客户端

Thrift客户端：被绑定在多种语言中，包括C++，Java，PHP，Python以及Ruby等
JDBC驱动：提供纯Java的JDBC驱动，连接字符串类似于jdbc:hive://*host*:*port*/*dbname*，除非使用了嵌入的模式，否则JDBC模式的驱动访问了Thrift服务器
ODBC驱动：与JDBC类似，但尚未成熟

Hive中的元数据存储metastore

metastore包括两个部分：服务和后台的数据存储

- Embedded metastore: 默认使用内嵌的Derby数据库实例，每次只能打开一个Hive会话
- Local metastore: 可以使用运行在一个进程中的metastore进程来访问独立的数据库，可通过JDBC进行设置具体的数据库访问
- Remote metastore: 一个或者多个metastore服务器和Hive服务运行在不同的进程内

metastore的配置情况